

MAP REDUCE (PYTHON)

Trường hợp bị lỗi không nhận python

```
hadoopkhai@khai-master:~/demoMRPy$ echo "foo foo quux labs foo bar quux" | /home/hadoopkhai/demoMRPy/mapper.py
/home/hadoopkhai/demoMRPy/mapper.py: line 1: mapper.py: command not found
/home/hadoopkhai/demoMRPy/mapper.py: line 3: import: command not found
/home/hadoopkhai/demoMRPy/mapper.py: line 8: syntax error near unexpected token `line'
/home/hadoopkhai/demoMRPy/mapper.py: line 8: `    line = line.strip()'
```

Tiến hành kiểm tra trong tập tin **mapper.py** đã có dòng sau đây hay chưa? Vì để chạy một tập lệnh Python dưới dạng lệnh, không sử dụng lệnh "python", dòng đầu tiên phải cho hệ thống biết trình thông dịch nào cần sử dụng. Đây được gọi là dòng "she-bang".

```
#!/usr/bin/env python
```

Nếu thực thi vẫn bị lỗi `/usr/bin/env: 'python': No such file or directory`

→ Kiểm tra đã cài đặt python3 → Chưa cài đặt

```
$ sudo apt-get install python3
```

Hoặc

```
$ sudo apt update
```

```
$ sudo apt install python-is-python3
```

→ Nếu đã cài đặt, xem thư mục cài python3

```
$ whereis python3
```

Tạo symbolic link tới thư mục chứa python

```
$ sudo ln -s /usr/bin/python3 /usr/bin/python
```

THỰC HÀNH

Viết chương trình MapReduce mô phỏng WordCount cho Hadoop bằng Python (không sử dụng Jython để dịch mã sang *.jar như trên Java)

Chương trình đọc các tệp văn bản và đếm tần suất xuất hiện của các từ. Đầu vào là các tệp văn bản và đầu ra là các tệp văn bản, mỗi dòng chứa một từ và số lần xuất hiện của từ đó, được phân tách bằng một tab.

Python MapReduce Code

Chúng ta sẽ sử dụng Hadoop Streaming API để truyền dữ liệu giữa mã Map và Reduce thông qua STDIN (đầu vào chuẩn) và STDOUT (đầu ra chuẩn). Sẽ chỉ sử dụng python sys.stdin để đọc dữ liệu đầu vào và in đầu ra vào sys.stdout. Đó là tất cả những gì cần làm vì Hadoop Streaming thực hiện các công đoạn còn lại.

\$ ls -l hadoop/share/hadoop/tools/lib

```
hadoopkhai@khai-master:~$ ls -l hadoop/share/hadoop/tools/lib
total 312216
-rw-r--r-- 1 hadoopkhai hadoopkhai 194215 Jul 29 2022 aliyun-java-sdk-core-4.5.10.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 163698 Jul 29 2022 aliyun-java-sdk-kms-2.11.0.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 220800 Jul 29 2022 aliyun-java-sdk-ram-3.1.0.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 782427 Jul 29 2022 aliyun-sdk-oss-3.13.0.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 280645251 Jul 29 2022 aws-java-sdk-bundle-1.12.262.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 113966 Jul 29 2022 azure-data-lake-store-sdk-2.3.9.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 10288 Jul 29 2022 azure-keyvault-core-1.0.0.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 815331 Jul 29 2022 azure-storage-7.0.1.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 63353 Jul 29 2022 hadoop-aliyun-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 27393 Jul 29 2022 hadoop-archive-logs-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 28411 Jul 29 2022 hadoop-archives-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 962685 Jul 29 2022 hadoop-aws-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 574116 Jul 29 2022 hadoop-azure-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 32208 Jul 29 2022 hadoop-azure-datalake-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 8556 Jul 29 2022 hadoop-client-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 20825 Jul 29 2022 hadoop-datajoin-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 157769 Jul 29 2022 hadoop-distcp-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 22487 Jul 29 2022 hadoop-dynamometer-blockgen-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 80740 Jul 29 2022 hadoop-dynamometer-infra-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 54340 Jul 29 2022 hadoop-dynamometer-workload-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 27901 Jul 29 2022 hadoop-extras-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 51355 Jul 29 2022 hadoop-fs2img-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 223935 Jul 29 2022 hadoop-gridmix-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 12847 Jul 29 2022 hadoop-kafka-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 7945 Jul 29 2022 hadoop-minicluster-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 124860 Jul 29 2022 hadoop-openstack-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 68546 Jul 29 2022 hadoop-resourceestimator-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 287090 Jul 29 2022 hadoop-rumen-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 370306 Jul 29 2022 hadoop-sls-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 141242 Jul 29 2022 hadoop-streaming-3.3.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 45024 Jul 29 2022 hamcrest-core-1.3.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 102220 Jul 29 2022 ini4j-0.5.4.jar
-rw-r--r-- 1 hadoopkhai hadoopkhai 18348545 Jul 29 2022 jdk.tools-1.8.jar
```

Khởi tạo tệp tin mapper.py

Lưu đoạn mã sau vào thư mục /home/hduser/mapper.py. Đọc dữ liệu từ STDIN, chia dữ liệu thành các từ và đưa ra danh sách các dòng ánh xạ các từ với số lượng (trung gian) thành STDOUT. Tuy nhiên, tệp lệnh Map sẽ không tính tổng (trung gian) của số lần xuất hiện của một từ. Thay vào đó, sẽ đưa ra <word> 1 các bộ ngay lập tức – mặc dù một từ cụ thể có thể xuất hiện nhiều lần trong đầu vào. Trong trường hợp này sẽ để bước Reduce tiếp theo thực hiện số đếm tổng cuối cùng.

Đảm bảo rằng có quyền thực thi (chmod 777 mapper.py thực hiện được).

```
#!/usr/bin/env python
"""reducer.py"""
from operator import itemgetter
import sys
current_word = None
current_count = 0
word = None

# input comes from STDIN
for line in sys.stdin:
    # remove leading and trailing whitespace
    line = line.strip()
    # parse the input we got from mapper.py
    word, count = line.split('\t', 1)
    # convert count (currently a string) to int
    try:
        count = int(count)
    except ValueError:
        # count was not a number, so silently
        # ignore/discard this line
        continue

    # this IF-switch only works because Hadoop sorts map output
    # by key (here: word) before it is passed to the reducer
    if current_word == word:
        current_count += count
    else:
        if current_word:
            # write result to STDOUT
            print('%s\t%s' % (current_word, current_count))
            current_count = count
            current_word = word

# do not forget to output the last word if needed!
if current_word == word:
    print('%s\t%s' % (current_word, current_count))
```

Khởi tạo tập tin reducer.py

Lưu đoạn mã sau vào thư mục /home/hduser/reducer.py. Đọc kết quả của mapper.py from STDIN (do đó định dạng đầu ra của mapper.py và định dạng đầu vào mong đợi của reducer.py phải giống nhau) và tính tổng số lần xuất hiện của từng từ thành số đếm cuối cùng, sau đó xuất kết quả thành STDOUT.

Đảm bảo rằng có quyền thực thi (chmod 777 reducer.py thực hiện được).

```
#!/usr/bin/env python
"""reducer.py"""
from operator import itemgetter
import sys
current_word = None
current_count = 0
word = None

# input comes from STDIN
for line in sys.stdin:
    # remove leading and trailing whitespace
    line = line.strip()
    # parse the input we got from mapper.py
    word, count = line.split('\t', 1)
    # convert count (currently a string) to int
    try:
        count = int(count)
    except ValueError:
        # count was not a number, so silently
        # ignore/discard this line
        continue

    # this IF-switch only works because Hadoop sorts map output
    # by key (here: word) before it is passed to the reducer
    if current_word == word:
        current_count += count
    else:
        if current_word:
            # write result to STDOUT
            print('%s\t%s' % (current_word, current_count))
            current_count = count
            current_word = word
        # do not forget to output the last word if needed!
    if current_word == word:
        print ('%s\t%s' % (current_word, current_count))
```

Test mã nguồn (cat data | map | sort | reduce)

Nên kiểm tra các tập lệnh mapper.py và reducer.py cục bộ trước khi sử dụng chúng trong công việc MapReduce. Nếu không, công việc của có thể hoàn thành thành công nhưng sẽ không có dữ liệu kết quả công việc nào cả hoặc không phải là kết quả đang mong đợi. Sau đây là một số ý tưởng về cách kiểm tra chức năng tập Map và Reduce.

```
$ echo "foo foo quux labs foo bar quux" | /home/hadoopkhai/demoMRPy/mapper.py
```

```
hadoopkhai@khai-master:~$ echo "foo foo quux labs foo bar quux" | /home/hadoopkhai/demoMRPy/mapper.py
foo      1
foo      1
quux     1
labs     1
foo      1
bar      1
quux     1
```

\$ echo "foo foo quux labs foo bar quux" | /home/hadoopkhai/demoMRPy/mapper.py |
sort -k1,1 | /home/hadoopkhai/demoMRPy/reducer.py

```
hadoopkhai@khai-master:~$ echo "foo foo quux labs foo bar quux" | /home/hadoopkhai/de
moMRPy/mapper.py | sort -k1,1 | /home/hadoopkhai/demoMRPy/reducer.py
bar      1
foo      3
labs     1
quux     2
```

\$ cat /tmp/gutenberg/pg4300.txt | /home/hadoopkhai/demoMRPy/mapper.py | more

```
hadoopkhai@khai-master:~$ cat /tmp/gutenberg/pg4300.txt | /home/hadoopkhai/demoMRPy/mapper.py | more
The      1
Project  1
Gutenberg      1
eBook      1
of          1
Ulysses     1
This        1
ebook       1
is          1
for          1
the         1
use         1
of          1
anyone      1
anywhere    1
in          1
the         1
United      1
States      1
and         1
most        1
other       1
parts       1
of          1
the         1
world       1
at          1
--More--
```

Thực thi chương trình python trên Hadoop

Đặt văn bản dưới dạng Plain Text mã hóa UTF-8 và lưu trữ các tập tin đó trong thư mục tạm thời cục bộ theo lựa chọn, ví dụ /tmp/gutenberg:

\$ ls -l /tmp/gutenberg/

```
hadoopkhai@khai-master:~$ ls -l /tmp/gutenberg/
total 1552
-rw-r--r-- 1 root root 1586392 Mar 16 04:04 pg4300.txt
```

Đưa tập tin lên HDFS của Hadoop

\$ hdfs dfs -copyFromLocal /tmp/gutenberg /user/hadoopkhai/gutenberg

\$ hdfs dfs -ls

\$ hdfs dfs -ls gutenberg

```
hadoopkhai@khai-master:~$ hdfs dfs -ls
Found 6 items
drwxr-xr-x   - hadoopkhai supergroup          0 2025-03-16 04:06 gutenber
drwxr-xr-x   - hadoopkhai supergroup          0 2025-02-24 01:25 input1
drwxr-xr-x   - hadoopkhai supergroup          0 2025-03-13 22:34 input_dir
drwxr-xr-x   - hadoopkhai supergroup          0 2025-03-08 17:55 output1
drwxr-xr-x   - hadoopkhai supergroup          0 2025-03-13 22:35 output_dir
drwxr-xr-x   - hadoopkhai supergroup          0 2025-02-24 01:34 remote
hadoopkhai@khai-master:~$ hdfs dfs -ls gutenber
Found 1 items
-rw-r--r--   2 hadoopkhai supergroup      1586392 2025-03-16 04:06 gutenber/pg4300.txt
hadoopkhai@khai-master:~$
```

Chạy tác vụ MapReduce

\$ hadoop jar hadoop/share/hadoop/tools/lib/hadoop-*streaming*.jar -file

/home/hadoopkhai/demoMRPy/mapper.py -mapper /home/hadoopkhai/demoMRPy/mapper.py -file

/home/hadoopkhai/demoMRPy/reducer.py -reducer /home/hadoopkhai/demoMRPy/reducer.py -input

gutenber/* -output gutenber-output

```
hadoopkhai@khai-master:~$ hadoop jar hadoop/share/hadoop/tools/lib/hadoop-*streaming*.jar -file /home/hadoopkhai/demoMRPy/mapper.py -mapper
/home/hadoopkhai/demoMRPy/mapper.py -file /home/hadoopkhai/demoMRPy/reducer.py -reducer /home/hadoopkhai/demoMRPy/reducer.py -input gutenber
/* -output gutenber-output
2025-03-16 04:32:25,293 WARN streaming.StreamJob: -file option is deprecated, please use generic option -files instead.
packageJobJar: [/home/hadoopkhai/demoMRPy/mapper.py, /home/hadoopkhai/demoMRPy/reducer.py, /tmp/hadoop-unjar8228995315559084230/] [] /tmp/strea
mjob8166279044980902072.jar tmpDir=null
2025-03-16 04:32:25,870 INFO client.DefaultNoHARMAFailoverProxyProvider: Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-03-16 04:32:26,030 INFO client.DefaultNoHARMAFailoverProxyProvider: Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-03-16 04:32:26,249 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/hadoop-yarn/staging/hadoopkhai/.staging/job
_1741773139491_0016
2025-03-16 04:32:26,501 INFO mapred.FileInputFormat: Total input files to process : 1
2025-03-16 04:32:26,569 INFO mapreduce.JobSubmitter: number of splits:2
2025-03-16 04:32:26,753 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1741773139491_0016
2025-03-16 04:32:26,753 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-03-16 04:32:26,882 INFO conf.Configuration: resource-types.xml not found
2025-03-16 04:32:26,882 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2025-03-16 04:32:27,238 INFO impl.YarnClientImpl: Submitted application application_1741773139491_0016
2025-03-16 04:32:27,292 INFO mapreduce.Job: The url to track the job: http://khai-master:9004/proxy/application_1741773139491_0016/
2025-03-16 04:32:27,294 INFO mapreduce.Job: Running job: job_1741773139491_0016
2025-03-16 04:32:32,403 INFO mapreduce.Job: Job job_1741773139491_0016 running in uber mode : false
2025-03-16 04:32:32,406 INFO mapreduce.Job: map 0% reduce 0%
2025-03-16 04:32:38,489 INFO mapreduce.Job: map 50% reduce 0%
2025-03-16 04:32:39,515 INFO mapreduce.Job: map 100% reduce 0%
2025-03-16 04:32:43,553 INFO mapreduce.Job: map 100% reduce 100%
2025-03-16 04:32:43,561 INFO mapreduce.Job: Job job_1741773139491_0016 completed successfully
2025-03-16 04:32:43,642 INFO mapreduce.Job: Counters: 54
File System Counters
FILE: Number of bytes read=2614876
FILE: Number of bytes written=6070407
```

Xem kết quả có được lưu trữ thành công trên HDFS

\$ hdfs dfs -ls gutenber-output

```
hadoopkhai@khai-master:~$ hdfs dfs -ls gutenber-output
Found 2 items
-rw-r--r--   2 hadoopkhai supergroup          0 2025-03-16 04:32 gutenber-output/_SUCCESS
-rw-r--r--   2 hadoopkhai supergroup      530411 2025-03-16 04:32 gutenber-output/part-00000
hadoopkhai@khai-master:~$
```

Kiểm tra nội dung

\$ hdfs dfs -cat gutenber-output/part-00000 | more

```

hadoopkhai@khai-master:~$ hdfs dfs -cat gutenber-output/part-00000 | more
#4300] 1
$5,000) 1
% 4
&c, 2
&c. 1
($1 1
(1 2
(1) 1
(1/4d, 1
(10/- 1
(1000 1
(17 1
(1880) 1
(1st 1
(2 2
(2/-) 1
(23 1
(2nd 1
(30 1
(5 1
(57,000,000,000,000 1
(7 1
(8 1
(801) 1
(Adam 1
(Albert 1
(Armageddon) : 1
(Aromatic) . 1
(B.) 1
--More--

```

Bài tập áp dụng:

1. Cho tập tin **emp_data.csv** có lược đồ (schema) như sau: mã nhân viên, tên nhân viên, vị trí công việc, mã người quản lý, ngày vào làm, lương, mã phòng ban. Hãy viết chương trình map-reduce để xử lý các yêu cầu sau:

- a. Tìm lương nhỏ nhất.
- b. Tìm đồng thời lương nhỏ nhất và lớn nhất.
- c. Tìm lương lớn nhất trên từng phòng ban.
- d. Hãy cho biết lương thấp nhất trên từng vị trí công việc.
- e. Hãy cho biết số lượng nhân viên mà mỗi mã quản lý giám sát.

BÀI TẬP VẬN DỤNG

1. Cho tập tin **transaction_data.csv**, hãy viết chương trình map-reduce để xử lý các yêu cầu sau:

- a. Có tổng cộng bao nhiêu hóa đơn.
- b. Tính tổng số hàng hóa được bán.
- c. Tính xem số lượng bán hàng trên từng sản phẩm.
- d. Tính xem số lượng đơn hàng được bán ở Tây Ban Nha.
- e. Tính xem số lượng hàng hóa được bán trong tháng 11.
- f. Tính xem mỗi khách hàng (UserId, TransactionId) mua bao nhiêu sản phẩm.
- g. Tính xem trung bình số hàng hóa được mua trên mỗi sản phẩm.

2. Cho tập dữ liệu [SalesJan2009.csv](#), hãy viết chương trình map-reduce để xử lý các yêu cầu sau:

- a. Tìm số lượng sản phẩm bán được ở mỗi quốc gia (Country).
- b. Hãy cho biết số lượng thành phố (City) ở mỗi bang (State)?
- c. Tìm số lần thực hiện mua bán ứng với mỗi khách hàng (Name)?
- d. Tìm khách hàng có số lần mua sắm nhiều nhất trong 07 ngày đầu tiên 01/2009?
- e. Cho biết sản phẩm nào được mua nhiều nhất?
- f. Cho biết tổng giá trị sản phẩm nào được bán nhiều nhất?

--- Hết ---