

Chuyển đổi các phiên bản Java – JDK

\$ sudo update-alternatives --config java

```
hadoopkhai@khai-master:~/hive$ sudo update-alternatives --config java
There are 2 choices for the alternative java (providing /usr/bin/java).

  Selection    Path                                          Priority    Status
  -----
  0            /usr/lib/jvm/java-11-openjdk-amd64/bin/java  1111       auto mode
  1            /usr/lib/jvm/java-11-openjdk-amd64/bin/java  1111       manual mode
  * 2          /usr/lib/jvm/java-8-openjdk-amd64/jre/bin/java 1081       manual mode

Press <enter> to keep the current choice[*], or type selection number: 0
update-alternatives: using /usr/lib/jvm/java-11-openjdk-amd64/bin/java to provide /usr/bin/java (java) in auto mode
hadoopkhai@khai-master:~/hive$
```

Cần kiểm tra phiên bản Apache Drill, Java tương thích với Apache Hadoop để cài đặt:


- ✓ Apache Hadoop 3.3.4
- ✓ Apache Pig 0.17.0
- ✓ OpenJdk 8

APACHE PIG

1. CÀI ĐẶT APACHE DRILL


1.1. Cài đặt chương trình Apache Pig

Truy cập <https://pig.apache.org/> chọn release page phiên bản mới nhất của Apache Pig (hoặc lựa chọn phiên bản tương thích Apache Hadoop đang sử dụng)



The screenshot shows the Apache Pig homepage. At the top, there's a navigation bar with 'Project' and 'Wiki' tabs. Below it, a sidebar on the left contains links like 'Welcome', 'Releases', 'About', 'Mailing Lists', 'Who We Are', 'Bylaws', 'Pig Tools', 'Privacy Policy', 'Sponsorship', 'Thanks', 'Documentation', and 'Developers'. The main content area has a 'Welcome to Apache Pig!' message, followed by a 'News' section announcing 'Apache Pig 0.17.0 is released!'. Below that is a 'Getting Started' section with links to 'Read the documentation', 'Find training resources', and 'Discuss it on the mailing list'. At the bottom, there's a 'Getting Involved' section. The page also features the Apache Hadoop logo and a search bar at the top right.

Chọn “Download a release now!”



The screenshot shows the 'Apache Pig Releases' page. It features a sidebar on the left with the same navigation links as the homepage. The main content area is titled 'Apache Pig Releases' and includes a 'Download' section with a list of release dates and versions, such as '10 June, 2017, release 0.17.0 available'. Below the list, there's a 'Download a release now!' button. The page also includes a 'Get Pig .rpm or .deb' section and a 'Get Pig from Maven' section. The Apache Hadoop logo and a search bar are visible at the top.

Chọn mục



We suggest the following location for your download:

<https://dlcdn.apache.org/pig>

Alternate download locations are suggested below.

It is essential that you [verify the integrity](#) of the downloaded file using the PGP signature (`.asc` file) or a hash (`.md5` or `.sha*` file).

HTTP

<https://dlcdn.apache.org/pig>

BACKUP SITES

<https://dlcdn.apache.org/pig>

Chọn thư mục latest/

Pig Releases

Please make sure you're downloading from [a nearby mirror site](#), not from www.apache.org.

Older releases are available from the [archives](#).

Name	Last modified	Size	Description
 Parent Directory		-	
 latest/	2022-06-17 12:56	-	
 pig-0.16.0/	2022-06-17 12:56	-	
 pig-0.17.0/	2022-06-17 12:56	-	
 KEYS	2017-06-19 08:12	11K	

Lần lượt tải xuống các tập tin `pig-x.xx.x-src.tar.gz` và `pig-x.xx.x.tar.gz`

Index of /pig/latest

Name	Last modified	Size	Description
 Parent Directory		-	
 README.txt	2017-06-16 18:10	1.4K	
 RELEASE_NOTES.txt	2017-06-16 18:10	1.9K	
 pig-0.17.0-src.tar.gz	2017-06-16 18:11	15M	
 pig-0.17.0-src.tar.gz.asc	2017-06-16 18:11	488	
 pig-0.17.0-src.tar.gz.md5	2017-06-16 18:11	56	
 pig-0.17.0.tar.gz	2017-06-16 18:10	220M	
 pig-0.17.0.tar.gz.asc	2017-06-16 18:11	488	
 pig-0.17.0.tar.gz.md5	2017-06-16 18:11	52	

Tạo thư mục cùng cấp với thư mục cài đặt Apache Hadoop

```
$ su hadoopkhai
```

```
$ mkdir pig
```

```
$ su root
```

```
$ cd /home/tqkhai/Downloads
```

```
$ tar zxvf pig-0.17.0-src.tar.gz
```

```
$ tar zxvf pig-0.17.0.tar.gz
```

```
$ mv pig-0.17.0-src /home/hadoopkhai/pig
```

```
$ sudo cp -r pig-0.17.0/* /home/hadoopkhai/pig
```

1.2. Cấu hình môi trường

Sau khi cài đặt Apache Pig, cần chỉnh sửa hai tệp **.bashrc** và **pig.properties**

Tập tin **.bashrc**

```
$ vi ~/.bashrc
```

```
export PIG_HOME=/home/hadoopkhai/pig
```

```
export PATH=$PATH:$PIG_HOME/bin
```

```
export PIG_CLASSPATH = $HADOOP_HOME/conf
```

Trong đó:

- **Thư mục PIG_HOME** vào thư mục cài đặt Apache Pigs,
- **Biến môi trường PATH** đến thư mục bin
- **Biến môi trường PIG_CLASSPATH** vào thư mục etc (cấu hình) trong cài đặt, hadoop (thư mục chứa các tệp core-site.xml, hdfs-site.xml và mapred-site.xml).

```
$ source ~/.bashrc
```

Tập tin **pig.properties**

Trong thư mục **conf** của Pig, có một tệp có tên là **pig.properties**. Trong tệp **pig.properties**, có thể thiết lập nhiều tham số khác nhau như được đưa ra bên dưới.

\$ pig -h properties

```
hadoopkhai@khai-master:~/pig$ pig -h properties
The following properties are supported:
Logging:
  verbose=true|false; default is false. This property is the same as -v switch
  brief=true|false; default is false. This property is the same as -b switch
  debug=OFF|ERROR|WARN|INFO|DEBUG; default is INFO. This property is the same as -d switch
  aggregate.warning=true|false; default is true. If true, prints count of warnings
    of each type rather than logging each warning.
Performance tuning:
  pig.cachedbag.memusage=<mem fraction>; default is 0.2 (20% of all memory).
    Note that this memory is shared across all large bags used by the application.
  pig.skewedjoin.reduce.memusage=<mem fraction>; default is 0.3 (30% of all memory).
    Specifies the fraction of heap available for the reducer to perform the join.
  pig.exec.nocombiner=true|false; default is false.
    Only disable combiner as a temporary workaround for problems.
  opt.multiquery=true|false; multiquery is on by default.
    Only disable multiquery as a temporary workaround for problems.
  opt.fetch=true|false; fetch is on by default.
    Scripts containing Filter, Foreach, Limit, Stream, and Union can be dumped without MR jobs.
  pig.tmpfilecompression=true|false; compression is off by default.
    Determines whether output of intermediate jobs is compressed.
  pig.tmpfilecompression.codec=lzo|gzip; default is gzip.
    Used in conjunction with pig.tmpfilecompression. Defines compression type.
  pig.noSplitCombination=true|false. Split combination is on by default.
    Determines if multiple small files are combined into a single map.
  pig.exec.mapPartAgg=true|false. Default is false.
    Determines if partial aggregation is done within map phase,
    before records are sent to combiner.
  pig.exec.mapPartAgg.minReduction=<min aggregation factor>. Default is 10.
    If the in-map partial aggregation does not reduce the output num records
    by this factor, it gets disabled.
Miscellaneous:
  exectype=mapreduce|tez|local; default is mapreduce. This property is the same as -x switch
  pig.additional.jars.uris=<comma seperated list of jars>. Used in place of register command.
  udf.import.list=<Colon seperated list of imports>. Used to avoid package names in UDF.
  stop.on.failure=true|false; default is false. Set to true to terminate on the first error.
  pig.datetime.default.tz=<UTC time offset>. e.g. +08:00. Default is the default timezone of the host.
    Determines the timezone used to handle datetime datatype and UDFs.
  pig.artifacts.download.location=<path to download artifacts>; default is ~/.groovy/grapes
    Determines the location to download the artifacts when registering jars using ivy coordinates.
Additionally, any Hadoop property can be specified.
2025-04-02 10:28:24,989 INFO pig.Main: Pig script completed in 55 milliseconds (55 ms)
hadoopkhai@khai-master:~/pig$
```

Kiểm chứng cài đặt Apache Pig

\$ pig -version

```
hadoopkhai@khai-master:~/pig$ pig -version
Apache Pig version 0.17.0 (r1797386)
compiled Jun 02 2017, 15:41:58
hadoopkhai@khai-master:~/pig$
```

2. Thực thi Apache Pig

2.1. Chế độ thực thi

Có thể gọi Grunt Shell ở chế độ mong muốn (Local/MapReduce) bằng cách sử dụng tùy chọn **-x** như hiển thị bên dưới.

2.1.1. Chế độ cục bộ (local)

\$ pig -x local

```
hadoopkhai@khai-master:~/pig$ pig -x local
2025-04-02 10:39:06,442 INFO pig.ExecTypeProvider: Trying ExecType : LOCAL
2025-04-02 10:39:06,443 INFO pig.ExecTypeProvider: Picked LOCAL as the ExecType
2025-04-02 10:39:06,498 [main] INFO org.apache.pig.Main - Apache Pig version 0.17.0 (r1797386) compiled Jun 02 2017, 15:41:58
2025-04-02 10:39:06,498 [main] INFO org.apache.pig.Main - Logging error messages to: /home/hadoopkhai/pig/pig_1743565146496.log
2025-04-02 10:39:06,520 [main] INFO org.apache.pig.impl.util.Utils - Default bootup file /home/hadoopkhai/.pigbootup not found
2025-04-02 10:39:06,586 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.job.tracker is deprecated. Instead, use mapreduce.jobtracker.address
2025-04-02 10:39:06,588 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to hadoop file system at: file:///
2025-04-02 10:39:06,658 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2025-04-02 10:39:06,679 [main] INFO org.apache.pig.PigServer - Pig Script ID for the session: FIG-default-7818c306-1a43-4b8b-9759-a6d0c64b0c81
2025-04-02 10:39:06,679 [main] WARN org.apache.pig.PigServer - ATS is disabled since yarn.timeline-service.enabled set to false
grunt$
```

2.1.2. Chế độ MapReduce

\$ pig -x mapreduce

```
hadoopkhai@khai-master:~/pig$ pig -x mapreduce
2025-04-02 10:40:29,016 INFO pig.ExecTypeProvider: Trying ExecType : LOCAL
2025-04-02 10:40:29,017 INFO pig.ExecTypeProvider: Trying ExecType : MAPREDUCE
2025-04-02 10:40:29,017 INFO pig.ExecTypeProvider: Picked MAPREDUCE as the ExecType
2025-04-02 10:40:29,065 INFO org.apache.pig.Main - Apache Pig version 0.17.0 (r1797386) compiled Jun 02 2017, 15:41:58
2025-04-02 10:40:29,065 [main] INFO org.apache.pig.Main - Logging error messages to: /home/hadoopkhai/pig/pig_1743565229058.log
2025-04-02 10:40:29,081 [main] INFO org.apache.pig.impl.util.Utils - Default bootstrap file /home/hadoopkhai/.pigbootstrap not found
2025-04-02 10:40:29,308 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.job.tracker is deprecated. Instead, use mapreduce.jobtracker.address
2025-04-02 10:40:29,309 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to hadoop file system at: hdfs://khai-master:9000
2025-04-02 10:40:29,684 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to map-reduce job tracker at: khai-master:9001
2025-04-02 10:40:29,701 [main] INFO org.apache.pig.PigServer - Pig Script ID for the session: PIG-default-4360d3c5-31ab-4783-80e1-92aa8efd92e6
2025-04-02 10:40:29,702 [main] WARN org.apache.pig.PigServer - ATS is disabled since yarn.timeline-service.enabled set to false
grunt>
```

Ví dụ:

Dùng Cho MapReduce → đưa dữ liệu lên hdfs

\$ hdfs dfs -copyFromLocal Lab08_customers.txt /user/hadoopkhai

\$ pig -x local

> customers = LOAD 'Lab08_customers.txt' USING PigStorage(',');

> dump customers;

```
HadoopVersion  PigVersion  UserId  StartedAt  FinishedAt  Features
3.3.4          0.17.0      hadoopkhai
2025-04-02 11:07:17  2025-04-02 11:07:18  UNKNOWN

Success!

Job Stats (time in seconds):
JobId  Maps  Reduces  MaxMapTime  MinMapTime  AvgMapTime  MedianMapTime  MaxReduceTime  MinReduceTime  AvgReduceTime  MedianReduceTime  Alias  Feature  Outputs
job_local1938661553_0001  1  0  n/a  n/a  n/a  n/a  0  0  0  customers  MAP_ONLY  file:/tmp/temp848065591/tmp-849761067,

Input(s):
Successfully read 4 records from: *file:///home/hadoopkhai/pig/Lab08_customers.txt*

Output(s):
Successfully stored 4 records in: *file:/tmp/temp848065591/tmp-849761067*

Counters:
Total records written : 4
Total bytes written : 0
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_local1938661553_0001

2025-04-02 11:07:18,275 [main] WARN org.apache.hadoop.metrics2.impl.MetricsSystemImpl - JobTracker metrics system already initialized!
2025-04-02 11:07:18,289 [main] WARN org.apache.hadoop.metrics2.impl.MetricsSystemImpl - JobTracker metrics system already initialized!
2025-04-02 11:07:18,293 [main] WARN org.apache.hadoop.metrics2.impl.MetricsSystemImpl - JobTracker metrics system already initialized!
2025-04-02 11:07:18,297 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapreduce.Launcher - Success!
2025-04-02 11:07:18,299 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - io.bytes.per.checksum is deprecated. Instead, use dfs.bytes-per-checksum
2025-04-02 11:07:18,300 [main] WARN org.apache.pig.data.SchemaTupleBackend - SchemaTupleBackend has already been initialized
2025-04-02 11:07:18,304 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 11:07:18,305 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(RB, account, 'sep', '1st', 'oscar', 'name')
('A-23-112', 'ashbb', 2234, 'Aug 13th', 'Satoshi')
('B-34-122', 'tiger', 5543, 'May 1st', 'Satish')
('A-15-982', 'pen', 7812, 'Sep 24th', 'Michael')
```

Hoặc có thể viết pig script chạy local:

\$ vi sample_script.pig

customers = LOAD 'Lab08_customers.txt' USING PigStorage(',');

Dump customers;

\$ pig -x local sample_script.pig

Hoặc

\$ pig -x mapreduce sample_script.pig

2.2. Grunt Shell

Sau khi gọi Grunt Shell, có thể chạy các tập lệnh Pig trong shell. Ngoài ra, còn có một số lệnh shell và tiện ích hữu ích do shell Grunt cung cấp.

2.2.1. Lệnh shell

Shell Grunt của Apache Pig chủ yếu được sử dụng để viết các tập lệnh Pig Latin, có thể gọi bất kỳ lệnh shell nào bằng cách sử dụng **sh** và **fs**.

Lệnh sh: sử dụng lệnh **sh**, có thể gọi bất kỳ lệnh shell nào từ shell Grunt tuy nhiên, không thể thực thi các lệnh là một phần của môi trường shell (**ví dụ:** **cd**).

Cú pháp:

grunt> sh shell command parameters

Ví dụ:

grunt> sh ls

```
grunt> sh ls
dbkemp.sql
demoMR
demoMRPy
drill
hadoop
hadoop-3.3.4.tar.gz
hive
input
Lab08_customers.txt
local
output1
output_dir
pi_classes
PiEstimator_classes
PiEstimator.jar
PiEstimator.java
```

2.2.2. Lệnh fs

Khi sử dụng lệnh **fs**, có thể gọi bất kỳ lệnh FsShell nào từ shell Grunt.

Cú pháp

grunt> sh File System command parameters

Ví dụ:

grunt> fs -ls

```
grunt> fs -ls
Found 1 items
-rw-r--r--    2 hadoopkhai supergroup      179 2025-04-02 11:03 Lab08_customers.txt
grunt>
```

2.2.3. Lệnh tiện ích

Cung cấp một tập hợp các lệnh tiện ích bao gồm các lệnh tiện ích như **clear**, **help**, **history**, **quit** và **set**; và các lệnh như **exec**, **kill** và **run** để điều khiển Pig từ shell Grunt.

Lệnh xóa: lệnh **clear** được sử dụng để xóa màn hình của shell Grunt.

grunt> clear

Lệnh help: lệnh **help** cung cấp cho bạn danh sách các lệnh Pig hoặc thuộc tính Pig.

grunt> help

Lệnh lịch sử: lệnh này hiển thị danh sách các câu lệnh đã được thực thi/sử dụng kể từ khi lệnh `sell` của Grunt được gọi.

```
grunt> history
```

Lệnh thiết lập: lệnh **set** được sử dụng để hiển thị/gán giá trị cho các khóa được sử dụng trong Pig.

Cách sử dụng

Sử dụng lệnh này, bạn có thể đặt giá trị cho các khóa sau.

Key	Mô tả và giá trị
default_parallel	Có thể thiết lập số lượng bộ giảm tốc cho tác vụ bản đồ bằng cách truyền bất kỳ số nguyên nào làm giá trị cho khóa này.
debug	Có thể tắt hoặc bật tính năng gỡ lỗi trong Pig bằng cách truyền phím bật/tắt cho phím này.
job.name	Có thể đặt Tên công việc thành công việc cần thiết bằng cách truyền giá trị chuỗi vào khóa này.
job.priority	Có thể thiết lập mức độ ưu tiên công việc cho một công việc bằng cách truyền một trong các giá trị sau vào khóa này – • rất_thấp • thấp • Bình thường • cao • rất_cao
stream.skippath	Đối với phát trực tuyến, có thể thiết lập đường dẫn mà dữ liệu không được truyền đi bằng cách truyền đường dẫn mong muốn dưới dạng chuỗi vào khóa này.

Lệnh thoát: dùng để thoát khỏi Grunt Shell

```
grunt> quit
```

Lệnh thực thi: sử dụng lệnh `exec`, có thể thực thi các tập lệnh Pig từ shell Grunt.

Cú pháp

```
grunt> exec [param param_name = param_value] [param_file file_name] [script]
```

Lệnh kill: kết thúc một công việc từ shell Grunt bằng lệnh này.

```
grunt> kill JobId
```


Lệnh run: chạy một tập lệnh Pig từ shell Grunt bằng lệnh **run**.

Cú pháp:

```
grunt> run [param param_name = param_value] [param_file file_name] script
```

Lưu ý: Sự khác biệt giữa lệnh **exec** và lệnh **run** là nếu sử dụng **lệnh run**, các câu lệnh từ tập lệnh sẽ có sẵn trong lịch sử lệnh.

3. Pig Latin

3.1. Pig Latin

Pig Latin là ngôn ngữ được sử dụng để phân tích dữ liệu trong Hadoop bằng Apache Pig. Giới thiệu về những điều cơ bản của Pig Latin như các câu lệnh Pig Latin, kiểu dữ liệu, toán tử chung và toán tử quan hệ, và Pig Latin UDF.

Khi xử lý dữ liệu bằng Pig Latin, **các câu lệnh** là cấu trúc cơ bản.

- ✓ Các câu lệnh này hoạt động với **các mối quan hệ**. Chúng bao gồm **các biểu thức** và **lược đồ**.
- ✓ Mỗi câu lệnh đều kết thúc bằng dấu chấm phẩy (;).
- ✓ Chúng ta sẽ thực hiện nhiều hoạt động khác nhau bằng cách sử dụng các toán tử do Pig Latin cung cấp thông qua các câu lệnh.
- ✓ Ngoại trừ LOAD và STORE, trong khi thực hiện tất cả các thao tác khác, các câu lệnh Pig Latin lấy một quan hệ làm đầu vào và tạo ra một quan hệ khác làm đầu ra.
- ✓ Ngay khi nhập câu lệnh **Load** vào shell Grunt, việc kiểm tra ngữ nghĩa của nó sẽ được thực hiện. Để xem nội dung của lược đồ, bạn cần sử dụng toán tử **Dump**. Chỉ sau khi thực hiện thao tác **dump**, tác vụ MapReduce để tải dữ liệu vào hệ thống tệp mới được thực hiện.

3.1.1. Kiểu dữ liệu Pig Latin

S.N.	Data Type	Description & Example
1	int	Represents a signed 32-bit integer. Example: 8
2	long	Represents a signed 64-bit integer. Example: 5L
3	float	Represents a signed 32-bit floating point. Example: 5.5F
4	double	Represents a 64-bit floating point. Example: 10.5
5	chararray	Represents a character array (string) in Unicode UTF-8 format. Example: tutorials point

6	Bytearray	Represents a Byte array (blob).
7	Boolean	Represents a Boolean value. Example: true/ false.
8	Datetime	Represents a date-time. Example: 1970-01-01T00:00:00.000+00:00
9	Biginteger	Represents a Java BigInteger. Example: 60708090709
10	Bigdecimal	Represents a Java BigDecimal. Example: 185.98376256272893883
Complex Types		
11	Tuple	A tuple is an ordered set of fields. Example: (raja, 30)
12	Bag	A bag is a collection of tuples. Example: {(raju,30), (Mohhammad,45)}
13	Map	A Map is a set of key-value pairs. Example: [name#Raju, age#30]

3.1.2. Giá trị NULL

Giá trị cho tất cả các kiểu dữ liệu trên có thể là NULL. Apache Pig xử lý các giá trị null theo cách tương tự như SQL. Null có thể là giá trị không xác định hoặc giá trị không tồn tại, được sử dụng như một trình giữ chỗ cho các giá trị tùy chọn. Các giá trị null này có thể xảy ra tự nhiên hoặc có thể là kết quả của một phép toán.

3.1.3. Toán tử số học Pig Latin

Bảng sau đây mô tả các toán tử số học của Pig Latin. Giả sử a = 10 và b = 20.

Operator	Description	Example
+	Addition: Adds values on either side of the operator	a + b will give 30
-	Subtraction – Subtracts right hand operand from left hand operand	a – b will give –10
*	Multiplication – Multiplies values on either side of the operator	a * b will give 200

/	Division – Divides left hand operand by right hand operand	b / a will give 2
%	Modulus – Divides left hand operand by right hand operand and returns remainder	b % a will give 0
? :	Bincond – Evaluates the Boolean operators. It has three operands as shown below. variable x = (expression) ? value1 if true : value2 if false.	b = (a == 1)? 20: 30; if a = 1 the value of b is 20. if a!=1 the value of b is 30.
CASE WHEN THEN ELSE END	Case – The case operator is equivalent to nested bincond operator.	CASE f2 % 2 WHEN 0 THEN 'even' WHEN 1 THEN 'odd' END

3.2. Các hàm trên Pig Latin

3.2.1. Pig Latin Comparison Operators

Bảng sau đây mô tả các toán tử so sánh của Pig Latin.

Operator	Description	Example
==	Equal – Checks if the values of two operands are equal or not; if yes, then the condition becomes true.	(a = b) is not true
!=	Not Equal – Checks if the values of two operands are equal or not. If the values are not equal, then condition becomes true.	(a != b) is true.
>	Greater than – Checks if the value of the left operand is greater than the value of the right operand. If yes, then the condition becomes true.	(a > b) is not true.
<	Less than – Checks if the value of the left operand is less than the value of the right operand. If yes, then the condition becomes true.	(a < b) is true.

$\geq$	Greater than or equal to – Checks if the value of the left operand is greater than or equal to the value of the right operand. If yes, then the condition becomes true.	(a $\geq$ b) is not true.
$\leq$	Less than or equal to – Checks if the value of the left operand is less than or equal to the value of the right operand. If yes, then the condition becomes true.	(a $\leq$ b) is true.
matches	Pattern matching – Checks whether the string in the left-hand side matches with the constant in the right-hand side.	fl matches <code>'.*tutorial.*'</code>

3.2.2. Pig Latin Type Construction Operators

Bảng sau đây mô tả các toán tử xây dựng Kiểu của Pig Latin.

Operator	Description	Example
()	Tuple constructor operator – This operator is used to construct a tuple.	(Raju, 30)
{}	Bag constructor operator – This operator is used to construct a bag.	{(Raju, 30), (Mohammad, 45)}
[]	Map constructor operator – This operator is used to construct a tuple.	[name#Raja, age#30]

3.2.3. Pig Latin Relational Operations

Bảng sau đây mô tả các toán tử quan hệ của Pig Latin.

Operator	Description
Loading and Storing	
LOAD	To Load the data from the file system (local/HDFS) into a relation.
STORE	To save a relation to the file system (local/HDFS).
Filtering	
FILTER	To remove unwanted rows from a relation.
DISTINCT	To remove duplicate rows from a relation.

FOREACH, GENERATE	To generate data transformations based on columns of data.
STREAM	To transform a relation using an external program.
Grouping and Joining	
JOIN	To join two or more relations.
COGROUP	To group the data in two or more relations.
GROUP	To group the data in a single relation.
CROSS	To create the cross product of two or more relations.
Sorting	
ORDER	To arrange a relation in a sorted order based on one or more fields (ascending or descending).
LIMIT	To get a limited number of tuples from a relation.
Combining and Splitting	
UNION	To combine two or more relations into a single relation.
SPLIT	To split a single relation into two or more relations.
Diagnostic Operators	
DUMP	To print the contents of a relation on the console.
DESCRIBE	To describe the schema of a relation.
EXPLAIN	To view the logical, physical, or MapReduce execution plans to compute a relation.
ILLUSTRATE	To view the step-by-step execution of a series of statements.

4. Các thao tác trên Apache Pig

4.1. Thao tác nạp và lưu dữ liệu (Load & Store)

Nhìn chung, Apache Pig hoạt động trên Hadoop. Đây là một công cụ phân tích phân tích các tập dữ liệu lớn tồn tại trong **Hadoop File System**. Để phân tích dữ liệu bằng Apache Pig, trước tiên phải tải dữ liệu vào Apache Pig. Phần thao tác này diễn giải cách tải dữ liệu vào Apache Pig từ HDFS.

Tạo thư mục trên hdfs

```
$ hdfs dfs -mkdir /user/hadoopkhai/pig_data
```

```
$ hdfs dfs -ls /
```

```
hadoopkhai@khai-master:~$ hdfs dfs -mkdir /pig_data
hadoopkhai@khai-master:~$ hdfs dfs -ls /
Found 4 items
drwxr-xr-x  - hadoopkhai supergroup          0 2025-04-02 14:41 /pig_data
-rw-r--r--  2 hadoopkhai supergroup        187 2025-04-02 11:16 /sample_script.pig
drwxr-xr-x  - hadoopkhai supergroup          0 2025-04-02 11:40 /tmp
drwxr-xr-x  - hadoopkhai supergroup          0 2025-04-02 11:32 /user
hadoopkhai@khai-master:~$
```

Chuẩn bị tập dữ liệu students.txt với nội dung như sau:

001,Rajiv,Reddy,9848022337,Hyderabad

002,siddarth,Battacharya,9848022338,Kolkata

003,Rajesh,Khanna,9848022339,Delhi

004,Preethi,Agarwal,9848022330,Pune

005,Trupthi,Mohanthi,9848022336,Bhuwaneshwar

006,Archana,Mishra,9848022335,Chennai.

Đưa dữ liệu lên hdfs

```
$ sudo chmod 666 students.txt
```

```
$ hdfs dfs -put students.txt /user/hadoopkhai/pig_data/
```

```
$ hdfs dfs -cat /user/hadoopkhai/pig_data/students.txt
```

```
hadoopkhai@khai-master:~$ sudo chmod 666 students.txt
[sudo] password for hadoopkhai:
hadoopkhai@khai-master:~$ hdfs dfs -put students.txt /pig_data
hadoopkhai@khai-master:~$ hdfs dfs -cat /pig_data/students.txt
001,Rajiv,Reddy,9848022337,Hyderabad
002,siddarth,Battacharya,9848022338,Kolkata
003,Rajesh,Khanna,9848022339,Delhi
004,Preethi,Agarwal,9848022330,Pune
005,Trupthi,Mohanthi,9848022336,Bhuwaneshwar
006,Archana,Mishra,9848022335,Chennaihadoopkhai@khai-master:~$
```

4.1.1. Thao tác nạp dữ liệu (Load)

Có thể tải dữ liệu vào Apache Pig từ hệ thống tập tin (HDFS/Local) bằng cách sử dụng toán tử LOAD của Pig Latin.

Câu lệnh load bao gồm hai phần được chia bởi toán tử =. Ở phía bên trái, cần đề cập đến tên của quan hệ mà chúng ta muốn lưu trữ dữ liệu và ở phía bên phải, do đó cần phải xác định cách lưu trữ dữ liệu. Cú pháp của toán tử Load được đưa ra dưới đây.

Cú pháp:

Relation_name = LOAD 'Input file path' USING function as schema;

- ✓ **relation_name**: phải đề cập đến mối quan hệ mà chúng ta muốn lưu trữ dữ liệu.
- ✓ **Đường dẫn tệp đầu vào**: phải đề cập đến thư mục HDFS nơi tệp được lưu trữ. (Ở chế độ MapReduce)
- ✓ **chức năng**: phải chọn một chức năng từ tập hợp các chức năng tải được cung cấp bởi Apache Pig (**BinStorage**, **JsonLoader**, **PigStorage**, **TextLoader**).
- ✓ **Sơ đồ**: phải định nghĩa sơ đồ của dữ liệu, có thể định nghĩa sơ đồ cần thiết như sau:

(column1: data type, column2: data type, column3: data type);

\$ pig -x mapreduce

```
grunt> student = LOAD 'pig_data/student_data.txt' USING PigStorage(',') as (id:int,
firstname: chararray, lastname: chararray, phone: chararray, city: chararray);
```

```
grunt> dump student
```

```
2025-04-02 15:03:59,928 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Unable to retrieve job to compute warning aggregation.
2025-04-02 15:03:59,928 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 15:03:59,929 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
2025-04-02 15:03:59,929 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... Will not generate code.
2025-04-02 15:03:59,952 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 15:03:59,952 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Rajiv,Reddy,9848022337,Hyderabad)
(2,siddarth,Battacharya,9848022338,Kolkata)
(3,Rajesh,Khanna,9848022339,Delhi)
(4,Preethi,Agarwal,9848022330,Pune)
(5,Trupthi,Mohanthy,9848022336,Bhuvaneshwar)
(6,Archana,Mishra,9848022335,Chennai)
grunt>
```

Trong đó:

Relation name	We have stored the data in the schema student .				
Input file path	We are reading data from the file student_data.txt , which is in the /pig_data/ directory of HDFS.				
Storage function	We have used the PigStorage() function. It loads and stores data as structured text files. It takes a delimiter using which each entity of a tuple is separated, as a parameter. By default, it takes \t as a parameter.				
schema	We have stored the data using the following schema.				
	column	id	firstname	lastname	phone
	datatype	int	char array	char array	char array

Lưu ý: Câu lệnh **load** sẽ chỉ tải dữ liệu vào mỗi quan hệ được chỉ định trong Pig. Để xác minh việc thực thi câu lệnh **Load**, phải sử dụng **Diagnostic Operators** trong phần tiếp theo.

Nếu bị lỗi:

```
2025-04-02 15:25:35,076 [main] INFO org.apache.hadoop.ipc.Client - Retrying
connect to server: 0.0.0.0/0.0.0.0:10020. Already tried 0 time(s); retry policy is
RetryUpToMaximumCountWithFixedSleep(maxRetries=10, sleepTime=1000
MILLISECONDS)
```

Thực hiện:

```
$ mr-jobhistory-daemon.sh start historyserver
```

4.1.2. Thao tác lưu dữ liệu (Store)

Cú pháp:

```
STORE Relation_name INTO 'required_directory_path' [USING function];
```

Lưu trữ mỗi quan hệ trong thư mục HDFS **/pig_Output/** như hiển thị bên dưới:

```
$ pig -x mapreduce
```

```
grunt> STORE student INTO 'pig_output/' USING PigStorage(',');
```

```
$ hdfs dfs -ls /user/hadoopkhai/pig_output
```

```
$ hdfs dfs -cat /user/hadoopkhai/pig_output/part-m-00000
```

```
hadoopkhai@khai-master:~$ hdfs dfs -ls /user/hadoopkhai/pig_output
Found 2 items
-rw-r--r-- 2 hadoopkhai supergroup 0 2025-04-02 15:15 /user/hadoopkhai/pig_output/_SUCCESS
-rw-r--r-- 2 hadoopkhai supergroup 223 2025-04-02 15:15 /user/hadoopkhai/pig_output/part-m-00000
hadoopkhai@khai-master:~$ hdfs dfs -cat /user/hadoopkhai/pig_output/part-m-00000
1,Rajiv,Reddy,9848022337,Hyderabad
2,siddarth,Battacharya,9848022338,Kolkata
3,Rajesh,Khanna,9848022339,Delhi
4,Preethi,Agarwal,9848022330,Pune
5,Trupthi,Mohanthi,9848022336,Bhuwaneshwar
6,Archana,Mishra,9848022335,Chennai
hadoopkhai@khai-master:~$
```

4.2. Thao tác chẩn đoán (Diagnostic)

Câu lệnh **load** sẽ chỉ tải dữ liệu vào mỗi quan hệ được chỉ định trong Apache Pig. Để xác minh việc thực thi câu lệnh **Load**, phải sử dụng **Diagnostic Operators**. Pig Latin cung cấp bốn loại toán tử chẩn đoán khác nhau:

- Dump operator
- Describe operator
- Explanation operator
- Illustration operator

4.2.1. Dump operator

Toán tử **Dump** được sử dụng để chạy các câu lệnh Pig Latin và hiển thị kết quả trên màn hình, thường được sử dụng để gỡ lỗi.

Cú pháp:

```
grunt> Dump Relation_Name;
```

Ví dụ:

```
grunt> dump student;
```

```
Success!
Job Stats (time in seconds):
JobId  Maps  Reduces MaxMapTime  MinMapTime  AvgMapTime  MedianMapTime  MaxReduceTime  MinReduceTime  AvgReduceTime  MedianReduceTime  Alias  Feature Outputs
job_1743582142334_0002  1      0      4      4      4      4      0      0      0      0      student MAP_ONLY  hdf://khai-master:9000/tmp/temp-781055595/tmp-1495589791,
91,

Input(s):
Successfully read 6 records (622 bytes) from: "hdfs://khai-master:9000/user/hadoopkhai/pig_data/students.txt"

Output(s):
Successfully stored 6 records (294 bytes) in: "hdfs://khai-master:9000/tmp/temp-781055595/tmp-1495589791"

Counters:
Total records written : 6
Total bytes written : 294
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1743582142334_0002

2025-04-02 15:29:47,040 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:29:47,044 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 15:29:47,084 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:29:47,091 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 15:29:47,139 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:29:47,144 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 15:29:47,220 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 15:29:47,221 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-m
etrics-publisher.enabled
2025-04-02 15:29:47,221 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 15:29:47,237 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 15:29:47,237 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Rajiv,Reddy,9848022337,Hyderabad)
(2,Siddarth,Battacharya,9848022338,Kolkata)
(3,Rajesh,Khanna,9848022339,Delhi)
(4,Preethi,Agarwal,9848022330,Pune)
(5,Trupthi,Mohanthi,9848022336,Bhuvaneshwar)
(6,Archana,Mishra,9848022335,Chennai)
grunt>
```

4.2.2. Describe operator

Toán tử **mô tả** được sử dụng để xem lược đồ của một quan hệ.

Cú pháp:

```
grunt> Describe Relation_name;
```

Ví dụL

```
grunt> describe student;
```

```
grunt> describe student
student: {id: int,firstname: chararray,lastname: chararray,phone: chararray,city: chararray}
grunt>
```

4.2.3. Explanation operator

Toán tử **giải thích** được sử dụng để hiển thị các kế hoạch thực thi logic, vật lý và MapReduce của một quan hệ.

Cú pháp:

```
grunt> explain Relation_name;
```

Ví dụ:

```
grunt> explain student;
```

```

grunt> explain student;
2025-04-02 15:37:18,017 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
2025-04-02 15:37:18,018 [main] WARN org.apache.pig.data.SchemaTupleBackend - SchemaTupleBackend has already been initialized
2025-04-02 15:37:18,018 [main] INFO org.apache.pig.newplan.logical.optimizer.LogicalPlanOptimizer - {RULES_ENABLED=[AddForEach, ColumnMapKeyPrune, ConstantCalculator, GroupByConstParallelSetter, LimitOptimizer, LoadTypeCastInserter, MergeFilter, MergeForEach, NestedLimitOptimizer, PartitionFilterOptimizer, PredicatePushdownOptimizer, PushDownForEachFlatten, PushUpFilter, SplitFilter, StreamTypeCastInserter]}
#-----
# New Logical Plan:
student: (Name: LOStore Schema: id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city#318:chararray)
|
|---student: (Name: LOForEach Schema: id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city#318:chararray)
|
|   (Name: LOGenerate[false,false,false,false,false] Schema: id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city#318:chararray)ColumnPrune:OutputUids=[314, 315, 316, 317, 318]ColumnPrune:InputUids=[314, 315, 316, 317, 318]
|   |
|   |   (Name: Cast Type: int Uid: 314)
|   |   |
|   |   |---id: (Name: Project Type: bytearray Uid: 314 Input: 0 Column: (*))
|   |   |
|   |   |   (Name: Cast Type: chararray Uid: 315)
|   |   |   |
|   |   |   |---firstname: (Name: Project Type: bytearray Uid: 315 Input: 1 Column: (*))
|   |   |   |
|   |   |   |   (Name: Cast Type: chararray Uid: 316)
|   |   |   |   |
|   |   |   |   |---lastname: (Name: Project Type: bytearray Uid: 316 Input: 2 Column: (*))
|   |   |   |   |
|   |   |   |   |   (Name: Cast Type: chararray Uid: 317)
|   |   |   |   |   |
|   |   |   |   |   |---phone: (Name: Project Type: bytearray Uid: 317 Input: 3 Column: (*))
|   |   |   |   |   |
|   |   |   |   |   |   (Name: Cast Type: chararray Uid: 318)
|   |   |   |   |   |   |
|   |   |   |   |   |   |---city: (Name: Project Type: bytearray Uid: 318 Input: 4 Column: (*))
|   |   |   |   |   |   |
|   |   |   |   |   |   |--- (Name: LOInnerLoad[0] Schema: id#314:bytearray)

```

grunt> explain student;

2025-04-02 15:37:18,017 [main] INFO

org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled

2025-04-02 15:37:18,018 [main] WARN org.apache.pig.data.SchemaTupleBackend - SchemaTupleBackend has already been initialized

2025-04-02 15:37:18,018 [main] INFO

org.apache.pig.newplan.logical.optimizer.LogicalPlanOptimizer -

{RULES_ENABLED=[AddForEach, ColumnMapKeyPrune, ConstantCalculator, GroupByConstParallelSetter, LimitOptimizer, LoadTypeCastInserter, MergeFilter, MergeForEach, NestedLimitOptimizer, PartitionFilterOptimizer, PredicatePushdownOptimizer, PushDownForEachFlatten, PushUpFilter, SplitFilter, StreamTypeCastInserter]}

#-----

New Logical Plan:

#-----

student: (Name: LOStore Schema:

id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city#318:chararray)

|

|---student: (Name: LOForEach Schema:

id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city#318:chararray)

|

|

```

| (Name: LOGenerate[false,false,false,false,false] Schema:
id#314:int,firstname#315:chararray,lastname#316:chararray,phone#317:chararray,city
#318:chararray)ColumnPrune:OutputUids=[314, 315, 316, 317,
318]ColumnPrune:InputUids=[314, 315, 316, 317, 318]
| | |
| | (Name: Cast Type: int Uid: 314)
| | |
| | |---id:(Name: Project Type: bytearray Uid: 314 Input: 0 Column: (*))
| | |
| | (Name: Cast Type: chararray Uid: 315)
| | |
| | |---firstname:(Name: Project Type: bytearray Uid: 315 Input: 1 Column: (*))
| | |
| | (Name: Cast Type: chararray Uid: 316)
| | |
| | |---lastname:(Name: Project Type: bytearray Uid: 316 Input: 2 Column: (*))
| | |
| | (Name: Cast Type: chararray Uid: 317)
| | |
| | |---phone:(Name: Project Type: bytearray Uid: 317 Input: 3 Column: (*))
| | |
| | (Name: Cast Type: chararray Uid: 318)
| | |
| | |---city:(Name: Project Type: bytearray Uid: 318 Input: 4 Column: (*))
| |
| |---(Name: LOInnerLoad[0] Schema: id#314:bytearray)
| |
| |---(Name: LOInnerLoad[1] Schema: firstname#315:bytearray)
| |
| |---(Name: LOInnerLoad[2] Schema: lastname#316:bytearray)
| |
| |---(Name: LOInnerLoad[3] Schema: phone#317:bytearray)
| |
| |---(Name: LOInnerLoad[4] Schema: city#318:bytearray)
|

```

```

|---student: (Name: LOLoad Schema:
id#314:bytearray,firstname#315:bytearray,lastname#316:bytearray,phone#317:bytearr
ay,city#318:bytearray)RequiredFields:null
#-----
# Physical Plan:
#-----
student: Store(fakefile:org.apache.pig.builtin.PigStorage) - scope-131
|
|---student: New For Each(false,false,false,false,false)[bag] - scope-130
| |
| | Cast[int] - scope-116
| |
| |
| | |---Project[bytearray][0] - scope-115
| |
| |
| | Cast[chararray] - scope-119
| |
| |
| | |---Project[bytearray][1] - scope-118
| |
| |
| | Cast[chararray] - scope-122
| |
| |
| | |---Project[bytearray][2] - scope-121
| |
| |
| | Cast[chararray] - scope-125
| |
| |
| | |---Project[bytearray][3] - scope-124
| |
| |
| | Cast[chararray] - scope-128
| |
| |
| | |---Project[bytearray][4] - scope-127
| |
|
|---student: Load(hdfs://khai-
master:9000/user/hadoopkhai/pig_data/students.txt:PigStorage(', ')) - scope-114

```

2025-04-02 15:37:18,035 [main] INFO

org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MRCompiler - File concatenation threshold: 100 optimistic? false

2025-04-02 15:37:18,038 [main] INFO

org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MultiQueryOptimizer - MR plan size before optimization: 1

2025-04-02 15:37:18,038 [main] INFO

org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MultiQueryOptimizer - MR plan size after optimization: 1

#-----

Map Reduce Plan

#-----

MapReduce node scope-132

Map Plan

student: Store(fakefile:org.apache.pig.builtin.PigStorage) - scope-131

|

|---student: New For Each(false,false,false,false,false)[bag] - scope-130

| |

| | Cast[int] - scope-116

| |

| | |---Project[bytearray][0] - scope-115

| |

| | Cast[chararray] - scope-119

| |

| | |---Project[bytearray][1] - scope-118

| |

| | Cast[chararray] - scope-122

| |

| | |---Project[bytearray][2] - scope-121

| |

| | Cast[chararray] - scope-125

| |

| | |---Project[bytearray][3] - scope-124

| |

| | Cast[chararray] - scope-128

```
| |
| |--Project[bytearray][4] - scope-127
|
|---student: Load(hdfs://khai-
master:9000/user/hadoopkhai/pig_data/students.txt:PigStorage(', ')) - scope-114-----
Global sort: false
```

4.2.4. Illustration operator

Toán tử **minh họa** cung cấp cách thực hiện từng bước một chuỗi các câu lệnh.

Cú pháp:

```
grunt> illustrate Relation_name;
```

Ví dụ:

```
grunt> illustrate student;
```

```
2025-04-02 15:41:04,922 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.PigMapOnly$Map - Aliases being processed per job phase (AliasName[line,offset]): M:
student[4,10] C: R:
| student | id:int | firstname:chararray | lastname:chararray | phone:chararray | city:chararray |
|         | 006   | Archana             | Mishra             | 9848022335      | Chennai        |
|-----|-----|-----|-----|-----|-----|
grunt> |
```

4.3. Thao tác gom nhóm và kết (Grouping & Joining)

4.3.1. Group Operator

Toán tử **GROUP** được sử dụng để nhóm dữ liệu trong một hoặc nhiều quan hệ. Nó thu thập dữ liệu có cùng khóa.

Cú pháp:

```
grunt> group_data = GROUP relation_name BY column_name;
```

Ví dụ:

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,   firstname:chararray,   lastname:chararray,   age:int,   phone:chararray,
city:chararray);
```

```
grunt> group_data = GROUP student_details by age;
```

```
grunt> dump group_data;
```

```
Input(s):
Successfully read 8 records (734 bytes) from: "hdfs://khai-master:9000/user/hadoopkhai/pig_data/student_details.txt"

Output(s):
Successfully stored 4 records (418 bytes) in: "hdfs://khai-master:9000/tmp/temp-1332009315/tmp-890830631"

Counters:
Total records written : 4
Total bytes written : 418
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1743582142334_0003

2025-04-02 15:47:12,801 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:47:12,805 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:47:12,836 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:47:12,848 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:47:12,877 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:47:12,880 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:47:12,910 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 15:47:12,913 [main] INFO org.apache.pig.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-
metrics-publisher.enabled
2025-04-02 15:47:12,915 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 15:47:12,925 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 15:47:12,925 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
H21, ((4,Preethi,Agarwal,21,9848022330,Pune),(1,Rajiv,Reddy,21,9848022337,Hyderabad)))
H22, ((3,Rajesh,Khanna,22,9848022339,Delhi),(2,siddarth,Battacharya,22,9848022338,Kolkata)))
H23, ((6,Archana,Mishra,23,9848022335,Chennai),(5,Trupthi,Mohanthy,23,9848022336,Bhuvaneshwar)))
H24, ((8,Bharathi,Nambiayyar,24,9848022333,Chennai),(7,Komal,Nayak,24,9848022334,trivendram)))
grunt>
```

grunt> Describe group_data;

```
grunt> Describe group_data;
group_data: {group: int,student_details: {(id: int,firstname: chararray,lastname: chararray,age: int,phone: chararray,city: chararray)}}
grunt>
```

grunt> Illustrate group_data;

```
2025-04-02 15:49:38,240 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.PigMapReduce$Reduce - Aliases being processed per job phase (AliasName[line,offset])
: M: student_details[9,18],student_details[-1,-1],group_data[10,13] C: R:

-----
| student_details | id:int | firstname:chararray | lastname:chararray | age:int | phone:chararray | city:chararray |
-----
|                 | 1     | Rajiv               | Reddy              | 21     | 9848022337     | Hyderabad      |
|                 | 4     | Preethi             | Agarwal            | 21     | 9848022330     | Pune            |
-----

| group_data      | group:int | student_details:bag{(tuple(id:int,firstname:chararray,lastname:chararray,age:int,phone:chararray,city:chararray))} |
-----
|                 | 21       | {(1, ..., Hyderabad), (4, ..., Pune)} |
-----

grunt>
```

grunt> group_multiple = GROUP student_details by (age, city);

grunt> dump group_multiple

```
Output(s):
Successfully stored 8 records (543 bytes) in: "hdfs://khai-master:9000/tmp/temp-1567544260/tmp-113168833"

Counters:
Total records written : 8
Total bytes written : 543
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1743582142334_0004

2025-04-02 15:50:32,148 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:50:32,154 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:50:32,168 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:50:32,178 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:50:32,200 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:50:32,209 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
ver
2025-04-02 15:50:32,236 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 15:50:32,236 [main] INFO org.apache.pig.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-
metrics-publisher.enabled
2025-04-02 15:50:32,237 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 15:50:32,243 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 15:50:32,243 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
((21,Pune),((4,Preethi,Agarwal,21,9848022330,Pune)))
((21,Hyderabad),((1,Rajiv,Reddy,21,9848022337,Hyderabad)))
((22,Delhi),((3,Rajesh,Khanna,22,9848022339,Delhi)))
((22,Kolkata),((2,siddarth,Battacharya,22,9848022338,Kolkata)))
((23,Chennai),((6,Archana,Mishra,23,9848022335,Chennai)))
((23,Bhuvaneshwar),((5,Trupthi,Mohanthy,23,9848022336,Bhuvaneshwar)))
((24,Chennai),((8,Bharathi,Nambiayyar,24,9848022333,Chennai)))
((24,trivendram),((7,Komal,Nayak,24,9848022334,trivendram)))
grunt>
```

grunt> group_all = GROUP student_details All;

grunt> dump group_all;

```

Input(s):
Successfully read 8 records (734 bytes) from: "hdfs://khai-master:9000/user/hadoopkhai/pig_data/student_details.txt"

Output(s):
Successfully stored 1 records (398 bytes) in: "hdfs://khai-master:9000/tmp/temp-1567544260/tmp-1331827149"

Counters:
Total records written : 1
Total bytes written : 398
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1743582142334_0005

2025-04-02 15:51:26,987 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:51:26,992 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
Ver
2025-04-02 15:51:27,019 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:51:27,025 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
Ver
2025-04-02 15:51:27,043 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 15:51:27,052 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history ser
Ver
2025-04-02 15:51:27,074 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 15:51:27,075 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-
metrics-publisher.enabled
2025-04-02 15:51:27,075 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 15:51:27,093 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 15:51:27,093 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(all, ((8,Bharathi,Nambiayar,24,9848022333,Chennai), (7,Komal,Nayak,24,9848022334,trivendram), (6,Archana,Mishra,23,9848022335,Chennai), (5,Trupthi,Mohanthy,23,9848022336,Bhuwaneshwar), (
4,Preethi,Agarwal,21,9848022330,Pune), (3,Rajesh,Khanna,22,9848022339,Delhi), (2,siddarth,Battacharya,22,9848022338,Kolkata), (1,Rajiv,Reddy,21,9848022337,Hyderabad)))
grunt>

```

4.3.2. Cogroup Operator

Toán tử **COGROUP** hoạt động giống với toán tử [GROUP](#). Sự khác biệt duy nhất giữa hai toán tử này là toán tử **nhóm** thường được sử dụng với một quan hệ, trong khi toán tử **cogroup** được sử dụng trong các câu lệnh liên quan đến hai hoặc nhiều quan hệ.

Nhóm Hai Quan Hệ Sử Dụng Cogroup

Giả sử có hai tệp là **student_details.txt** và **employee_details.txt** trong thư mục HDFS **/pig_data/** như hiển thị bên dưới.

student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad
 002,siddarth,Battacharya,22,9848022338,Kolkata
 003,Rajesh,Khanna,22,9848022339,Delhi
 004,Preethi,Agarwal,21,9848022330,Pune
 005,Trupthi,Mohanthy,23,9848022336,Bhuwaneshwar
 006,Archana,Mishra,23,9848022335,Chennai
 007,Komal,Nayak,24,9848022334,trivendram
 008,Bharathi,Nambiayar,24,9848022333,Chennai

employee_details.txt

001,Robin,22,newyork
 002,BOB,23,Kolkata
 003,Maya,23,Tokyo
 004,Sara,25,London
 005,David,23,Bhuwaneshwar
 006,Maggy,22,Chennai

Thực hiện:


```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',')
as (id:int, firstname:chararray, lastname:chararray, age:int, phone:chararray,
city:chararray);
```

```
grunt> employee_details = LOAD 'pig_data/employee_details.txt' USING
PigStorage(',') as (id:int, name:chararray, age:int, city:chararray);
```

Nhóm các bộ dữ liệu của các quan hệ **student_details** và **employee_details** với khóa age, như được hiển thị bên dưới.

```
grunt> cogroup_data = COGROUP student_details by age, employee_details by age;
```

```
grunt> dump cogroup_data;
```

```
Success!
Job Stats (time in seconds):
JobId  Maps  Reduces  MaxMapTime  MinMapTime  AvgMapTime  MedianMapTime  MaxReduceTime  MinReduceTime  AvgReduceTime  MedianReduceTime  Alias  Feature Outputs
job_1743582142334_0006  2  1  3  3  3  2  2  2  2  2  cogroup_data,employee_details,student_details  COGROUP  hdfs://khai-master:9000
/tmp/temp-1567544260/tmp320221503,

Input(s):
Successfully read 8 records from: "hdfs://khai-master:9000/user/hadoopkhai/pig_data/student_details.txt"
Successfully read 6 records from: "hdfs://khai-master:9000/user/hadoopkhai/pig_data/employee_details.txt"

Output(s):
Successfully stored 5 records (576 bytes) in: "hdfs://khai-master:9000/tmp/temp-1567544260/tmp320221503"

Counters:
Total records written : 5
Total bytes written : 576
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1743582142334_0006

2025-04-02 16:01:23,849 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:01:23,855 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:01:23,882 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:01:23,901 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:01:23,918 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:01:23,921 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:01:23,937 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:01:23,938 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-m
etrics-publisher.enabled
2025-04-02 16:01:23,938 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:01:23,944 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:01:23,944 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(21, ((4,Preethi,Agarwal,21,9848022330,Pune), (1,Rajiv,Reddy,21,9848022337,Hyderabad)), ())
(22, ((3,Rajesh,Khanna,22,9848022339,Delhi), (2,siddarth,Battacharya,22,9848022338,Kolkata)), ((6,Maggy,22,Chennai), (1,Robin,22,newyork)))
(23, ((6,Archana,Mishra,23,9848022335,Chennai), (5,Trupthi,Mohanthay,23,9848022336,Bhuaneshwar)), ((5,David,23,Bhuaneshwar), (3,Maya,23,Tokyo), (2,BOB,23,Kolkata)))
(24, ((8,Bharathi,Namhiyar,24,9848022333,Chennai), (7,Komal,Wayak,24,9848022334,trivendram)), ())
(25, (), ((4,Sara,25,London)))
grunt>
```

Toán tử nhóm **chung** nhóm các bộ từ mỗi quan hệ theo độ tuổi, trong đó mỗi nhóm mô tả một giá trị độ tuổi cụ thể.

Ví dụ, nếu xem xét bộ thứ nhất của kết quả, được nhóm theo độ tuổi 21 và chứa hai cụm

- Cụm đầu tiên chứa tất cả các bộ từ mỗi quan hệ đầu tiên (**student_details** trong trường hợp này) có tuổi là 21.
- Cụm thứ hai chứa tất cả các bộ từ mỗi quan hệ thứ hai (trong trường hợp này là **employee_details**) có độ tuổi là 21.

Trong trường hợp một quan hệ không có các giá trị tuổi là 21, sẽ trả về một cụm rỗng.

4.3.3. Join Operator

Toán tử **JOIN** được sử dụng để kết hợp các bản ghi từ hai hoặc nhiều mối quan hệ. Trong khi thực hiện một hoạt động nối, khai báo một (hoặc một nhóm) tuple từ mỗi mối quan hệ, như các khóa. Khi các khóa này khớp, hai tuple cụ thể được khớp, nếu không các bản ghi sẽ bị loại bỏ. Các phép nối có thể có các loại sau:

- Tự tham gia
- Inner-join

- Outer-join – left join, right join và full join

Giả sử có hai tệp là **customers.txt** và **orders.txt** trong thư mục **/pig_data/** của HDFS

customers.txt

```
1,Ramesh,32,Ahmedabad,2000.00
2,Khilan,25,Delhi,1500.00
3,kaushik,23,Kota,2000.00
4,Chaitali,25,Mumbai,6500.00
5,Hardik,27,Bhopal,8500.00
6,Komal,22,MP,4500.00
7,Muffy,24,Indore,10000.00
```

orders.txt

```
102,2009-10-08 00:00:00,3,3000
100,2009-10-08 00:00:00,3,1500
101,2009-11-20 00:00:00,2,1560
103,2008-05-20 00:00:00,4,2060
```

```
grunt> customers = LOAD 'pig_data/customers.txt' USING PigStorage(',') as (id:int,
name:chararray, age:int, address:chararray, salary:int);
```

```
grunt> orders = LOAD 'pig_data/orders.txt' USING PigStorage(',') as (oid:int,
date:chararray, customer_id:int, amount:int);
```

❖ self-join

Cú pháp:

```
grunt> Relation3_name = JOIN Relation1_name BY key, Relation2_name BY key ;
```

Ví dụ:

```
grunt> customers1 = LOAD 'pig_data/customers.txt' USING PigStorage(',') as (id:int,
name:chararray, age:int, address:chararray, salary:int);
```

```
grunt> customers2 = LOAD 'pig_data/customers.txt' USING PigStorage(',') as (id:int,
name:chararray, age:int, address:chararray, salary:int);
```

```
grunt> customers3 = JOIN customers1 BY id, customers2 BY id;
```

```
grunt> dump customer3;
```

```
2025-04-02 16:09:03,378 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:09:03,386 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:09:03,420 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:09:03,436 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:09:03,463 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:09:03,466 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
er
2025-04-02 16:09:03,502 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 8 time(s).
2025-04-02 16:09:03,502 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:09:03,503 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-m
etrics-publisher.enabled
2025-04-02 16:09:03,504 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:09:03,513 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:09:03,513 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Ramesh,32,Ahmedabad,2000,1,Ramesh,32,Ahmedabad,2000)
(2,Khilan,25,Delhi,1500,2,Khilan,25,Delhi,1500)
(3,kaushik,23,Kota,2000,3,kaushik,23,Kota,2000)
(4,Chaitali,25,Mumbai,6500,4,Chaitali,25,Mumbai,6500)
(5,Hardik,27,Bhopal,8500,5,Hardik,27,Bhopal,8500)
(6,Komal,22,MP,4500,6,Komal,22,MP,4500)
```

❖ inner-join

Inner Join được sử dụng khá thường xuyên; cũng được gọi là equijoin. Inner join trả về các hàng khi có sự khớp nhau trong cả hai bảng.

Tạo ra một mối quan hệ mới bằng cách kết hợp các giá trị cột của hai mối quan hệ (ví dụ A và B) dựa trên join-predicate. Truy vấn so sánh từng hàng của A với từng hàng của B để tìm tất cả các cặp hàng thỏa mãn join-predicate. Khi join-predicate được thỏa mãn, các giá trị cột cho mỗi cặp hàng khớp của A và B được kết hợp thành một hàng kết quả.

Cú pháp

```
grunt> result = JOIN relation1 BY columnname, relation2 BY columnname;
```

Ví dụ:

```
grunt> customer_orders = JOIN customers BY id, orders BY customer_id;
```

```
grunt> dump customer_orders;
```

```
2025-04-02 16:11:54,896 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:11:54,900 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
2025-04-02 16:11:54,921 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:11:54,931 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
2025-04-02 16:11:54,949 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:11:54,953 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history serv
2025-04-02 16:11:54,972 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 7 time(s).
2025-04-02 16:11:54,972 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:11:54,972 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-m
2025-04-02 16:11:54,973 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:11:54,991 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:11:54,991 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(2,Khilan,25,Delhi,1500,101,2009-11-20 00:00:00,2,1360)
(3,Kaushik,23,Kota,2000,100,2009-10-08 00:00:00,3,1500)
(3,Kaushik,23,Kota,2000,102,2009-10-08 00:00:00,3,3000)
(4,Chaitali,25,Mumbai,6500,103,2008-05-20 00:00:00,4,2060)
grunt>
```

Lưu ý

Outer Join : Không giống như inner join, **outer join** trả về tất cả các hàng từ ít nhất một trong các mối quan hệ. Một hoạt động outer join được thực hiện theo ba cách –

- Nối ngoài bên trái
- Nối ngoài bên phải
- Nối ngoài đầy đủ

❖ Left Outer Join

Hoạt động nối ngoài bên trái trả về tất cả các hàng từ bảng bên trái, ngay cả khi không có kết quả khớp nào trong quan hệ bên phải.

Cú pháp

```
grunt> Relation3_name = JOIN Relation1_name BY id LEFT OUTER,
Relation2_name BY customer_id;
```

Ví dụ:

```
grunt> outer_left = JOIN customers BY id LEFT OUTER, orders BY customer_id;
```

```
grunt> dump outer_left;
```

```

2025-04-02 16:15:12,985 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:15:12,988 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history server
2025-04-02 16:15:13,016 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:15:13,019 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history server
2025-04-02 16:15:13,039 [main] INFO org.apache.hadoop.yarn.client.DefaultNoHARMAFailoverProxyProvider - Connecting to ResourceManager at khai-master/192.168.111.1:9003
2025-04-02 16:15:13,043 [main] INFO org.apache.hadoop.mapred.ClientServiceDelegate - Application state is completed. FinalApplicationStatus=SUCCEEDED. Redirecting to job history server
2025-04-02 16:15:13,070 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 7 time(s).
2025-04-02 16:15:13,070 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:15:13,071 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
2025-04-02 16:15:13,071 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:15:13,076 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:15:13,076 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Ramesh,32,Ahmedabad,2000,,,)
(2,Khilan,25,Delhi,1500,101,2009-11-20 00:00:00,2,1560)
(3,Kaushik,23,Kota,2000,100,2009-10-08 00:00:00,3,1500)
(3,Kaushik,23,Kota,2000,102,2009-10-08 00:00:00,3,3000)
(4,Chaitali,25,Mumbai,6500,103,2008-05-20 00:00:00,4,2060)
(5,Hardik,27,Bhopal,8500,,,)
(6,Komal,22,MP,4500,,,)
(7,Muffy,24,Indore,10000,,,)
(,,,,,,,,)
grunt>

```



❖ Right Outer Join

Hoạt động nối ngoài bên phải trả về tất cả các hàng từ bảng bên phải, ngay cả khi không có kết quả khớp nào trong bảng bên trái.

Cú pháp

```
grunt> outer_right = JOIN customers BY id RIGHT, orders BY customer_id;
```

Ví dụ

```
grunt> outer_right = JOIN customers BY id RIGHT, orders BY customer_id;
```

```
grunt> dump outer_right;
```

```

2025-04-02 16:17:09,915 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 7 time(s).
2025-04-02 16:17:09,915 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:17:09,916 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
2025-04-02 16:17:09,916 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:17:09,921 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:17:09,922 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(2,Khilan,25,Delhi,1500,101,2009-11-20 00:00:00,2,1560)
(3,Kaushik,23,Kota,2000,100,2009-10-08 00:00:00,3,1500)
(3,Kaushik,23,Kota,2000,102,2009-10-08 00:00:00,3,3000)
(4,Chaitali,25,Mumbai,6500,103,2008-05-20 00:00:00,4,2060)
(,,,,,,,,)
grunt>

```



❖ Full Outer Join

Hoạt động nối ngoài đầy đủ trả về các hàng khi có sự khớp nhau trong một trong các quan hệ.

Cú pháp

```
grunt> outer_full = JOIN customers BY id FULL OUTER, orders BY customer_id;
```

Ví dụ:

```
grunt> outer_full = JOIN customers BY id FULL OUTER, orders BY customer_id;
```

```
grunt> dump outer_full;
```

```

2025-04-02 16:18:57,025 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 7 time(s).
2025-04-02 16:18:57,025 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!
2025-04-02 16:18:57,025 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled
2025-04-02 16:18:57,026 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:18:57,037 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:18:57,037 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Ramesh,32,Ahmedabad,2000,,,)
(2,Khilan,25,Delhi,1500,101,2009-11-20 00:00:00,2,1560)
(3,Kaushik,23,Kota,2000,100,2009-10-08 00:00:00,3,1500)
(3,Kaushik,23,Kota,2000,102,2009-10-08 00:00:00,3,3000)
(4,Chaitali,25,Mumbai,6500,103,2008-05-20 00:00:00,4,2060)
(5,Hardik,27,Bhopal,8500,,,)
(6,Komal,22,MP,4500,,,)
(7,Muffy,24,Indore,10000,,,)
(,,,,,,,,)
(,,,,,,,,)
grunt>

```



❖ Kết sử dụng nhiều khóa

Cú pháp:

```
grunt> Relation3_name = JOIN Relation2_name BY (key1, key2), Relation3_name BY (key1, key2);
```

Cho **employee.txt** và **employee_contact.txt** trong thư mục **/pig_data/** của HDFS.

employee.txt

001,Rajiv,Reddy,21,programmer,003
002,siddarth,Battacharya,22,programmer,003
003,Rajesh,Khanna,22,programmer,003
004,Preethi,Agarwal,21,programmer,003
005,Trupthi,Mohanthi,23,programmer,003
006,Archana,Mishra,23,programmer,003
007,Komal,Nayak,24,teamlead,002
008,Bharathi,Nambiyar,24,manager,001

employee_contact.txt

001,9848022337,Rajiv@gmail.com,Hyderabad,003
002,9848022338,siddarth@gmail.com,Kolkata,003
003,9848022339,Rajesh@gmail.com,Delhi,003
004,9848022330,Preethi@gmail.com,Pune,003
005,9848022336,Trupthi@gmail.com,Bhuwaneshwar,003
006,9848022335,Archana@gmail.com,Chennai,003
007,9848022334,Komal@gmail.com,trivendram,002
008,9848022333,Bharathi@gmail.com,Chennai,001

Thực hiện

```
grunt> employee = LOAD 'pig_data/employee.txt' USING PigStorage(',') as (id:int,  
firstname:chararray, lastname:chararray, age:int, designation:chararray, jobid:int);
```

```
grunt> employee_contact = LOAD 'pig_data/employee_contact.txt' USING  
PigStorage(',') as (id:int, phone:chararray, email:chararray, city:chararray, jobid:int);
```

Kết nội dung của hai quan hệ này bằng toán tử **JOIN** .

```
grunt> emp = JOIN employee BY (id,jobid), employee_contact BY (id,jobid);
```

```
grunt> dump emp;
```

```
2025-04-02 16:24:45,867 [main] WARN org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Encountered Warning ACCESSING_NON_EXISTENT_FIELD 9 time(s).  
2025-04-02 16:24:45,867 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MapReduceLauncher - Success!  
2025-04-02 16:24:45,867 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - yarn.resourcemanager.system-metrics-publisher.enabled is deprecated. Instead, use yarn.system-metrics-publisher.enabled  
2025-04-02 16:24:45,868 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.  
2025-04-02 16:24:45,875 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1  
2025-04-02 16:24:45,875 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1  
(1,Rajiv,Reddy,21,programmer,3,1,9848022337,Rajiv@gmail.com,Hyderabad,3)  
(2,siddarth,Battacharya,22,programmer,3,2,9848022338,siddarth@gmail.com,Kolkata,3)  
(3,Rajesh,Khanna,22,programmer,3,3,9848022339,Rajesh@gmail.com,Delhi,3)  
(4,Preethi,Agarwal,21,programmer,3,4,9848022330,Preethi@gmail.com,Pune,3)  
(5,Trupthi,Mohanthi,23,programmer,3,5,9848022336,Trupthi@gmail.com,Bhuwaneshwar,3)  
(6,Archana,Mishra,23,programmer,3,6,9848022335,Archana@gmail.com,Chennai,3)  
(7,Komal,Nayak,24,teamlead,2,7,9848022334,Komal@gmail.com,trivendram,2)  
(8,Bharathi,Nambiyar,24,manager,1,8,9848022333,Bharathi@gmail.com,Chennai,1)  
grunt> |
```

4.3.4. Cross Operator

Toán tử **CROSS** tính tích chéo của hai hoặc nhiều quan hệ.

Ví dụ: cho hai quan hệ customers.txt và orders.txt


```
grunt> customers = LOAD 'pig_data/customers.txt' USING PigStorage(',') as (id:int,
name:chararray, age:int, address:chararray, salary:int);

grunt> orders = LOAD 'pig_data/orders.txt' USING PigStorage(',') as (oid:int,
date:chararray, customer_id:int, amount:int);

grunt> cross_data = CROSS customers, orders;
```

```
2025-04-02 16:27:26,033 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:27:26,037 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:27:26,037 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(,,,,,)
(,,,,,103,2008-05-20 00:00:00,4,2060)
(,,,,,101,2009-11-20 00:00:00,2,1560)
(,,,,,100,2009-10-08 00:00:00,3,1500)
(,,,,,102,2009-10-08 00:00:00,3,3000)
(7,Muffy,24,Indore,10000,,,,)
(7,Muffy,24,Indore,10000,103,2008-05-20 00:00:00,4,2060)
(7,Muffy,24,Indore,10000,101,2009-11-20 00:00:00,2,1560)
(7,Muffy,24,Indore,10000,100,2009-10-08 00:00:00,3,1500)
(7,Muffy,24,Indore,10000,102,2009-10-08 00:00:00,3,3000)
(6,Komal,22,MP,4500,,,,)
(6,Komal,22,MP,4500,103,2008-05-20 00:00:00,4,2060)
(6,Komal,22,MP,4500,101,2009-11-20 00:00:00,2,1560)
(6,Komal,22,MP,4500,100,2009-10-08 00:00:00,3,1500)
(6,Komal,22,MP,4500,102,2009-10-08 00:00:00,3,3000)
(5,Hardik,27,Bhopal,8500,,,,)
(5,Hardik,27,Bhopal,8500,103,2008-05-20 00:00:00,4,2060)
(5,Hardik,27,Bhopal,8500,101,2009-11-20 00:00:00,2,1560)
(5,Hardik,27,Bhopal,8500,100,2009-10-08 00:00:00,3,1500)
(5,Hardik,27,Bhopal,8500,102,2009-10-08 00:00:00,3,3000)
(4,Chaitali,25,Mumbai,6500,,,,)
(4,Chaitali,25,Mumbai,6500,103,2008-05-20 00:00:00,4,2060)
(4,Chaitali,25,Mumbai,6500,101,2009-11-20 00:00:00,2,1560)
(4,Chaitali,25,Mumbai,6500,100,2009-10-08 00:00:00,3,1500)
(4,Chaitali,25,Mumbai,6500,102,2009-10-08 00:00:00,3,3000)
(3,Kaushik,23,Kota,2000,,,,)
(3,Kaushik,23,Kota,2000,103,2008-05-20 00:00:00,4,2060)
(3,Kaushik,23,Kota,2000,101,2009-11-20 00:00:00,2,1560)
(3,Kaushik,23,Kota,2000,100,2009-10-08 00:00:00,3,1500)
(3,Kaushik,23,Kota,2000,102,2009-10-08 00:00:00,3,3000)
(2,Khilan,25,Delhi,1500,,,,)
(2,Khilan,25,Delhi,1500,103,2008-05-20 00:00:00,4,2060)
(2,Khilan,25,Delhi,1500,101,2009-11-20 00:00:00,2,1560)
(2,Khilan,25,Delhi,1500,100,2009-10-08 00:00:00,3,1500)
(2,Khilan,25,Delhi,1500,102,2009-10-08 00:00:00,3,3000)
(1,Ramesh,32,Ahmedabad,2000,,,,)
(1,Ramesh,32,Ahmedabad,2000,103,2008-05-20 00:00:00,4,2060)
(1,Ramesh,32,Ahmedabad,2000,101,2009-11-20 00:00:00,2,1560)
(1,Ramesh,32,Ahmedabad,2000,100,2009-10-08 00:00:00,3,1500)
(1,Ramesh,32,Ahmedabad,2000,102,2009-10-08 00:00:00,3,3000)
grunt>
```

4.4. Thao tác tổ hợp và phân tách (Combining & Splitting)

4.4.1. Union Operator

Toán tử UNION của Pig Latin được sử dụng để hợp nhất nội dung của hai quan hệ. Để thực hiện phép toán UNION trên hai quan hệ, các cột và miền phải giống hệt nhau.

Cú pháp

```
grunt> Relation_name3 = UNION Relation_name1, Relation_name2;
```

Ví dụ:

Cho student_data1.txt và student_data2.txt trong thư mục /pig_data/ của HDFS.

student_data1.txt

```
001,Rajiv,Reddy,9848022337,Hyderabad
002,siddarth,Battacharya,9848022338,Kolkata
003,Rajesh,Khanna,9848022339,Delhi
004,Preethi,Agarwal,9848022330,Pune
005,Trupthi,Mohanthy,9848022336,Bhuwaneshwar
006,Archana,Mishra,9848022335,Chennai.
```

student_data2.txt

7,Komal,Nayak,9848022334,trivendram.

8,Bharathi,Nambiayar,9848022333,Chennai.

```
grunt> student1 = LOAD 'pig_data/student_data1.txt' USING PigStorage(',') as (id:int,
firstname:chararray, lastname:chararray, phone:chararray, city:chararray);
```

```
grunt> student2 = LOAD 'pig_data/student_data2.txt' USING PigStorage(',') as (id:int,
firstname:chararray, lastname:chararray, phone:chararray, city:chararray);
```

```
grunt> student = UNION student1, student2;
```

```
grunt> dump student;
```

```
2025-04-02 16:32:46,606 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:32:46,611 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 2
2025-04-02 16:32:46,611 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 2
(1,Rajiv,Reddy,9848022337,Hyderabad)
(2,siddarth,Battacharya,9848022338,Kolkata)
(3,Rajesh,Khanna,9848022339,Delhi)
(4,Preethi,Agarwal,9848022330,Pune)
(5,Trupthi,Mohanthi,9848022336,Bhuwaneshwar)
(6,Archana,Mishra,9848022335,Chennai.)
(,,,)
(7,Komal,Nayak,9848022334,trivendram.)
(8,Bharathi,Nambiayar,9848022333,Chennai.)
(,,,)
grunt> █
```

4.4.2. Split Operator

Toán tử **SPLIT** được sử dụng để chia một quan hệ thành hai hoặc nhiều quan hệ.

Cú pháp

```
grunt> SPLIT Relation1_name INTO Relation2_name IF (condition1),
Relation2_name (condition2),
```

Ví dụ

Cho **student_details.txt** trong thư mục HDFS **/pig_data/**
student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,  firstname:chararray,  lastname:chararray,  age:int,  phone:chararray,
city:chararray);
```

Bây giờ chia mỗi quan hệ này thành hai phần, một phần liệt kê những nhân viên có độ tuổi dưới 23 và phần còn lại liệt kê những nhân viên có độ tuổi từ 22 đến 25.

```
grunt> SPLIT student_details into student_details1 if age<23, student_details2 if (23<=age and age<25);
```

```
grunt> dump student_details1;
```

```
2025-04-02 16:36:42,481 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:36:42,494 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:36:42,494 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Rajiv,Reddy,21,9848022337,Hyderabad)
(2,siddarth,Battacharya,22,9848022338,Kolkata)
(3,Rajesh,Khanna,22,9848022339,Delhi)
(4,Preethi,Agarwal,21,9848022330,Pune)
grunt>
```

```
grunt> dump student_details2;
```

```
2025-04-02 16:48:32,694 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:48:32,699 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:48:32,699 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(5,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar)
(6,Archana,Mishra,23,9848022335,Chennai)
(7,Komal,Nayak,24,9848022334,trivendram)
(8,Bharathi,Nambiayar,24,9848022333,Chennai)
grunt>
```

4.5. Thao tác lọc (Filtering)

4.5.1. Filter Operator

Toán tử FILTER được sử dụng để chọn các bộ dữ liệu cần thiết từ một quan hệ dựa trên một điều kiện.

Cú pháp

```
grunt> Relation2_name = FILTER Relation1_name BY (condition);
```

Ví dụ

Cho student_details.txt trong thư mục HDFS /pig_data/

student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,   firstname:chararray,   lastname:chararray,   age:int,   phone:chararray,
city:chararray);
```

```
grunt> filter_data = FILTER student_details BY city == 'Chennai';
```

```
grunt> dump filter_data;
```

```
2025-04-02 16:50:08,208 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:50:08,214 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:50:08,214 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(6,Archana,Mishra,23,9848022335,Chennai)
(8,Bharathi,Nambiayar,24,9848022333,Chennai)
grunt>
```


4.5.2. Distinct Operator

Toán tử DISTINCT được sử dụng để loại bỏ các bộ dữ liệu trùng lặp khỏi một quan hệ.

Cú pháp

```
grunt> Relation_name2 = DISTINCT Relatin_name1;
```

Ví dụ

Cho student_details.txt trong thư mục HDFS /pig_data/

student_details.txt

001,Rajiv,Reddy,9848022337,Hyderabad

002,siddarth,Battacharya,9848022338,Kolkata

002,siddarth,Battacharya,9848022338,Kolkata

003,Rajesh,Khanna,9848022339,Delhi

003,Rajesh,Khanna,9848022339,Delhi

004,Preethi,Agarwal,9848022330,Pune

005,Trupthi,Mohanthi,9848022336,Bhuwaneshwar

006,Archana,Mishra,9848022335,Chennai

006,Archana,Mishra,9848022335,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as  
(id:int, firstname:chararray, lastname:chararray, phone:chararray, city:chararray);
```

```
grunt> distinct_data = DISTINCT student_details;
```

```
grunt> dump distinct_data;
```

(1,Rajiv,Reddy,9848022337,Hyderabad)

(2,siddarth,Battacharya,9848022338,Kolkata)

(3,Rajesh,Khanna,9848022339,Delhi)

(4,Preethi,Agarwal,9848022330,Pune)

(5,Trupthi,Mohanthi,9848022336,Bhuwaneshwar)

(6,Archana,Mishra,9848022335,Chennai)

4.5.3. Foreach Operator

Toán tử FOREACH được sử dụng để tạo ra các chuyển đổi dữ liệu được chỉ định dựa trên dữ liệu cột.

Cú pháp

```
grunt> Relation_name2 = FOREACH Relatin_name1 GENERATE (required data);
```

Ví dụ

Cho student_details.txt trong thư mục HDFS /pig_data/

student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,      firstname:chararray,      lastname:chararray,age:int,      phone:chararray,
city:chararray);
```

Bây giờ lấy giá trị id, age và city của mỗi sinh viên từ quan hệ student_details và lưu trữ nó vào một quan hệ khác có tên foreach_data bằng cách sử dụng toán tử foreach.

```
grunt> foreach_data = FOREACH student_details GENERATE id,age,city;
grunt> dump foreach_data;
```

```
2025-04-02 16:53:40,092 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,21,Hyderabad)
(2,22,Kolkata)
(3,22,Delhi)
(4,21,Pune)
(5,23,Bhuwaneshwar)
(6,23,Chennai)
(7,24,trivendram)
(8,24,Chennai)
grunt>
```

4.6. Thao tác sắp xếp (Sorting)

4.6.1. Order BY

Toán tử ORDER BY được sử dụng để hiển thị nội dung của một quan hệ theo thứ tự được sắp xếp dựa trên một hoặc nhiều trường.

Cú pháp

Dưới đây là cú pháp của toán tử ORDER BY .

```
grunt> Relation_name2 = ORDER Relatin_name1 BY (ASC|DESC);
```

Ví dụ

Cho student_details.txt trong thư mục HDFS /pig_data/
student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,      firstname:chararray,      lastname:chararray,age:int,      phone:chararray,
city:chararray);
```

Bây giờ sắp xếp mối quan hệ theo thứ tự giảm dần dựa trên độ tuổi của học sinh và lưu trữ vào mối quan hệ khác có tên là order_by_data bằng sử dụng toán tử ORDER BY.

```
grunt> order_by_data = ORDER student_details BY age DESC;
grunt> dump order_by_data;
```

```
2025-04-02 16:56:30,646 [main] INFO org.apache.pig.data.SchemaTupleBackend - Key [pig.schematuple] was not set... will not generate code.
2025-04-02 16:56:30,648 [main] INFO org.apache.hadoop.mapreduce.lib.input.FileInputFormat - Total input files to process : 1
2025-04-02 16:56:30,648 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(8,Bharathi,Nambiayar,24,9848022333,Chennai)
(7,Komal,Nayak,24,9848022334,trivendram)
(6,Archana,Mishra,23,9848022335,Chennai)
(5,Trupthi,Mohanthy,23,9848022336,Bhuwaneshwar)
(3,Rajesh,Khanna,22,9848022339,Delhi)
(2,siddarth,Battacharya,22,9848022338,Kolkata)
(4,Preethi,Agarwal,21,9848022330,Pune)
(1,Rajiv,Reddy,21,9848022337,Hyderabad)
grunt> █
```

4.6.2. Limit Operator

Toán tử LIMIT được sử dụng để lấy một số lượng giới hạn các bộ từ một quan hệ.

Cú pháp

```
grunt> Result = LIMIT Relation_name required number of tuples;
```

Ví dụ

Cho student_details.txt trong thư mục HDFS /pig_data/

student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthy,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student_details = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as
(id:int,      firstname:chararray,      lastname:chararray,age:int,      phone:chararray,
city:chararray);
```

Bây giờ, hãy sắp xếp mối quan hệ theo thứ tự giảm dần dựa trên độ tuổi của học sinh và lưu trữ vào mối quan hệ khác có tên là limit_data bằng toán tử ORDER BY.

```
grunt> limit_data = LIMIT student_details 4;
grunt> dump limit_data;
```

```
2025-04-02 16:57:54,856 [main] INFO org.apache.pig.backend.hadoop.executionengine.util.MapRedUtil - Total input paths to process : 1
(1,Rajiv,Reddy,21,9848022337,Hyderabad)
(2,siddarth,Battacharya,22,9848022338,Kolkata)
(3,Rajesh,Khanna,22,9848022339,Delhi)
(4,Preethi,Agarwal,21,9848022330,Pune)
grunt> █
```

4.7. Hàm Pig Latin

4.7.1. Eval Functions

Apache Pig cung cấp nhiều hàm tích hợp: eval, load, store, math, string, bag và tuple.

#	Function & Description
1	<u>AVG()</u> To compute the average of the numerical values within a bag.
2	<u>BagToString()</u> To concatenate the elements of a bag into a string. While concatenating, we can place a delimiter between these values (optional).
3	<u>CONCAT()</u> To concatenate two or more expressions of same type.
4	<u>COUNT()</u> To get the number of elements in a bag, while counting the number of tuples in a bag.
5	<u>COUNT_STAR()</u> It is similar to the COUNT() function. It is used to get the number of elements in a bag.
6	<u>DIFF()</u> To compare two bags (fields) in a tuple.
7	<u>IsEmpty()</u> To check if a bag or map is empty.
8	<u>MAX()</u> To calculate the highest value for a column (numeric values or chararrays) in a single-column bag.
9	<u>MIN()</u> To get the minimum (lowest) value (numeric or chararray) for a certain column in a single-column bag.
10	<u>PluckTuple()</u> Using the Pig Latin PluckTuple() function, we can define a string Prefix and filter the columns in a relation that begin with the given prefix.
11	<u>SIZE()</u> To compute the number of elements based on any Pig data type.
12	<u>SUBTRACT()</u> To subtract two bags. It takes two bags as inputs and returns a bag which contains the tuples of the first bag that are not in the second bag.

13	<u>SUM()</u> To get the total of the numeric values of a column in a single-column bag.
14	<u>TOKENIZE()</u> To split a string (which contains a group of words) in a single tuple and return a bag which contains the output of the split operation.

4.7.2. Load & Store Functions

Các hàm Load và Store trong Apache Pig được sử dụng để xác định cách dữ liệu đi và ra khỏi Pig. Các hàm này được sử dụng với các toán tử load và store. Dưới đây là danh sách các hàm load và store có trong Pig.

#	Function & Description
1	<u>PigStorage()</u> To load and store structured files.
2	<u>TextLoader()</u> To load unstructured data into Pig.
3	<u>BinStorage()</u> To load and store data into Pig using machine readable format.
4	<u>Handling Compression</u> In Pig Latin, we can load and store compressed data.

4.7.3. Bag & Tuple Functions

#	Function & Description
1	<u>TOBAG()</u> To convert two or more expressions into a bag.
2	<u>TOP()</u> To get the top N tuples of a relation.
3	<u>TOTUPLE()</u> To convert one or more expressions into a tuple.
4	<u>TOMAP()</u> To convert the key-value pairs into a Map.

4.7.4. String Functions

#	Functions & Description
1	<u>ENDSWITH(string, testAgainst)</u> To verify whether a given string ends with a particular substring.
2	<u>STARTSWITH(string, substring)</u> Accepts two string parameters and verifies whether the first string starts with the second.

3	<u>SUBSTRING(string, startIndex, stopIndex)</u> Returns a substring from a given string.
4	<u>EqualsIgnoreCase(string1, string2)</u> To compare two strings ignoring the case.
5	<u>INDEXOF(string, character, startIndex)</u> Returns the first occurrence of a character in a string, searching forward from a start index.
6	<u>LAST INDEX OF(expression)</u> Returns the index of the last occurrence of a character in a string, searching backward from a start index.
7	<u>LCFIRST(expression)</u> Converts the first character in a string to lower case.
8	<u>UCFIRST(expression)</u> Returns a string with the first character converted to upper case.
9	<u>UPPER(expression)</u> UPPER(expression) Returns a string converted to upper case.
10	<u>LOWER(expression)</u> Converts all characters in a string to lower case.
11	<u>REPLACE(string, oldChar, newChar);</u> To replace existing characters in a string with new characters.
12	<u>STRSPLIT(string, regex, limit)</u> To split a string around matches of a given regular expression.
13	<u>STRSPLITTOBAG(string, regex, limit)</u> Similar to the STRSPLIT() function, it splits the string by given delimiter and returns the result in a bag.
14	<u>TRIM(expression)</u> Returns a copy of a string with leading and trailing whitespaces removed.
15	<u>LTRIM(expression)</u> Returns a copy of a string with leading whitespaces removed.
16	<u>RTRIM(expression)</u> Returns a copy of a string with trailing whitespaces removed.

4.7.5. Date-time Functions

#	Functions & Description
1	<u>ToDate(milliseconds)</u> This function returns a date-time object according to the given parameters. The other alternative for this function are ToDate(iosstring), ToDate(userstring, format), ToDate(userstring, format, timezone)

2	<u>CurrentTime()</u> returns the date-time object of the current time.
3	<u>GetDay(datetime)</u> Returns the day of a month from the date-time object.
4	<u>GetHour(datetime)</u> Returns the hour of a day from the date-time object.
5	<u>GetMilliSecond(datetime)</u> Returns the millisecond of a second from the date-time object.
6	<u>GetMinute(datetime)</u> Returns the minute of an hour from the date-time object.
7	<u>GetMonth(datetime)</u> Returns the month of a year from the date-time object.
8	<u>GetSecond(datetime)</u> Returns the second of a minute from the date-time object.
9	<u>GetWeek(datetime)</u> Returns the week of a year from the date-time object.
10	<u>GetWeekYear(datetime)</u> Returns the week year from the date-time object.
11	<u>GetYear(datetime)</u> Returns the year from the date-time object.
12	<u>AddDuration(datetime, duration)</u> Returns the result of a date-time object along with the duration object.
13	<u>SubtractDuration(datetime, duration)</u> Subtracts the Duration object from the Date-Time object and returns the result.
14	<u>DaysBetween(datetime1, datetime2)</u> Returns the number of days between the two date-time objects.
15	<u>HoursBetween(datetime1, datetime2)</u> Returns the number of hours between two date-time objects.
16	<u>MilliSecondsBetween(datetime1, datetime2)</u> Returns the number of milliseconds between two date-time objects.
17	<u>MinutesBetween(datetime1, datetime2)</u> Returns the number of minutes between two date-time objects.
18	<u>MonthsBetween(datetime1, datetime2)</u> Returns the number of months between two date-time objects.
19	<u>SecondsBetween(datetime1, datetime2)</u> Returns the number of seconds between two date-time objects.

20	<u>WeeksBetween(datetime1, datetime2)</u> Returns the number of weeks between two date-time objects.
21	<u>YearsBetween(datetime1, datetime2)</u> Returns the number of years between two date-time objects.

4.7.6. Math Functions

#	Functions & Description
1	<u>ABS(expression)</u> To get the absolute value of an expression.
2	<u>ACOS(expression)</u> To get the arc cosine of an expression.
3	<u>ASIN(expression)</u> To get the arc sine of an expression.
4	<u>ATAN(expression)</u> This function is used to get the arc tangent of an expression.
5	<u>CBRT(expression)</u> This function is used to get the cube root of an expression.
6	<u>CEIL(expression)</u> This function is used to get the value of an expression rounded up to the nearest integer.
7	<u>COS(expression)</u> This function is used to get the trigonometric cosine of an expression.
8	<u>COSH(expression)</u> This function is used to get the hyperbolic cosine of an expression.
9	<u>EXP(expression)</u> This function is used to get the Eulers number e raised to the power of x.
10	<u>FLOOR(expression)</u> To get the value of an expression rounded down to the nearest integer.
11	<u>LOG(expression)</u> To get the natural logarithm (base e) of an expression.
12	<u>LOG10(expression)</u> To get the base 10 logarithm of an expression.
13	<u>RANDOM()</u> To get a pseudo random number (type double) greater than or equal to 0.0 and less than 1.0.
14	<u>ROUND(expression)</u>

	To get the value of an expression rounded to an integer (if the result type is float) or rounded to a long (if the result type is double).
15	<u>SIN(expression)</u> To get the sine of an expression.
16	<u>SINH(expression)</u> To get the hyperbolic sine of an expression.
17	<u>SQRT(expression)</u> To get the positive square root of an expression.
18	<u>TAN(expression)</u> To get the trigonometric tangent of an angle.
19	<u>TANH(expression)</u> To get the hyperbolic tangent of an expression.

4.8. User Defined Functions (undone)

Ngoài các hàm tích hợp, Apache Pig còn cung cấp hỗ trợ mở rộng cho **các hàm** do người **dùng định** nghĩa (UDF). Sử dụng các UDF này, có thể định nghĩa các hàm của riêng mình và sử dụng chúng. Hỗ trợ UDF được cung cấp trong sáu ngôn ngữ lập trình, cụ thể là Java, Jython, Python, JavaScript, Ruby và Groovy.

Để viết UDF, hỗ trợ đầy đủ được cung cấp trong Java và hỗ trợ hạn chế được cung cấp trong tất cả các ngôn ngữ còn lại. Sử dụng Java, bạn có thể viết UDF liên quan đến tất cả các phần của quá trình xử lý như tải/lưu trữ dữ liệu, chuyển đổi cột và tổng hợp. Vì Apache Pig được viết bằng Java, nên UDF được viết bằng ngôn ngữ Java hoạt động hiệu quả hơn so với các ngôn ngữ khác.

Trong Apache Pig, cũng có một kho lưu trữ Java cho UDF có tên là **Piggybank**. Sử dụng Piggybank, có thể truy cập các UDF Java do người dùng khác viết và đóng góp UDF của riêng mình.

Các loại UDF trong Java: khi viết UDF bằng Java, có thể tạo và sử dụng ba loại hàm:

- **Hàm lọc** – Hàm lọc được sử dụng như điều kiện trong các câu lệnh lọc. Các hàm này chấp nhận giá trị Pig làm đầu vào và trả về giá trị Boolean.
- **Hàm Eval** – Hàm Eval được sử dụng trong các câu lệnh FOREACH-GENERATE. Các hàm này chấp nhận giá trị Pig làm đầu vào và trả về kết quả Pig.
- **Các hàm đại số** – Các hàm đại số tác động lên các tuple bên trong trong câu lệnh FOREACHGENERATE. Các hàm này được sử dụng để thực hiện các hoạt động MapReduce đầy đủ trên một tuple bên trong.

4.8.1. Viết UDF bằng Java

Để viết UDF bằng Java, phải tích hợp tệp jar **Pig-0.15.0.jar**. Trong phần này, cách viết UDF mẫu bằng Visual Code. Trước khi tiếp tục, hãy đảm bảo rằng đã cài đặt Visual Code và Maven (<https://code.visualstudio.com/docs/java/java-build>).

Thực hiện theo các bước dưới đây để viết hàm UDF:

- Mở Visual Code và tạo một dự án mới (ví dụ: **myproject**).
- Chuyển đổi dự án mới tạo thành dự án Maven.
- Sao chép nội dung sau vào pom.xml. Tệp này chứa các phụ thuộc Maven cho Apache Pig và các tệp jar Hadoop-core.

4.8.2. Sử dụng UDF

4.9. Running Scripts

Xem cách chạy tập lệnh Apache Pig ở chế độ Batch.

Chú thích trong Pig Script

Khi viết một tập lệnh trong một tệp, có thể thêm các chú thích vào đó như được hiển thị bên dưới.

Chú thích nhiều dòng: sẽ bắt đầu chú thích nhiều dòng bằng '/*', kết thúc bằng '*/'.

```
/* These are the multi-line comments
```

```
In the pig script */
```

Chú thích một dòng: sẽ bắt đầu phân bình luận một dòng bằng ký tự '--'.

```
--we can write single line comments like this.
```

Thực hiện Pig Script ở chế độ Batch

Khi thực thi các câu lệnh Apache Pig ở chế độ Batch, thực hiện các bước:

Bước 1

Viết tất cả các câu lệnh Pig Latin cần thiết trong một tệp duy nhất, có thể viết tất cả các câu lệnh và lệnh Pig Latin trong một tệp duy nhất và lưu dưới dạng tệp ***.pig**

Bước 2

Thực thi tập lệnh Apache Pig, có thể thực thi tập lệnh Pig từ shell (Linux) như được hiển thị bên dưới.

Chế độ cục bộ	Chế độ MapReduce
\$ pig -x cục bộ Sample_script.pig	\$ pig -x mapreduce Sample_script.pig

Có thể thực thi nó từ shell Grunt bằng cách sử dụng lệnh exec như hiển thị bên dưới.

```
grunt> exec /sample_script.pig
```

Thực hiện Pig Script từ HDFS

Có thể thực thi một tập lệnh Pig nằm trong HDFS. Giả sử có một tập lệnh Pig có tên **Sample_script.pig** trong thư mục HDFS có tên là **/pig_data/**

```
$ pig -x mapreduce pig_data/Sample_script.pig
```

Ví dụ

Cho **student_details.txt** trong HDFS với nội dung sau.

student_details.txt

001,Rajiv,Reddy,21,9848022337,Hyderabad

002,siddarth,Battacharya,22,9848022338,Kolkata

003,Rajesh,Khanna,22,9848022339,Delhi

004,Preethi,Agarwal,21,9848022330,Pune

005,Trupthi,Mohanthi,23,9848022336,Bhuwaneshwar

006,Archana,Mishra,23,9848022335,Chennai

007,Komal,Nayak,24,9848022334,trivendram

008,Bharathi,Nambiayar,24,9848022333,Chennai

```
grunt> student = LOAD 'pig_data/student_details.txt' USING PigStorage(',') as (id:int,  
firstname: chararray, lastname: chararray, phone: chararray, city: chararray);
```

```
grunt> student_order = ORDER student BY age DESC;
```

```
grunt> student_limit = LIMIT student_order 4;
```

```
grunt> dump student_limit;
```

- Câu lệnh đầu tiên của tập lệnh sẽ tải dữ liệu trong tệp có tên **student_details.txt** dưới dạng một quan hệ có tên là **student**.
- Câu lệnh thứ hai của tập lệnh sẽ sắp xếp các cặp của mỗi quan hệ theo thứ tự giảm dần, dựa trên độ tuổi và lưu trữ dưới dạng **student_order**.
- Câu lệnh thứ ba của tập lệnh sẽ lưu trữ 4 bộ đầu tiên của **student_order** dưới dạng **student_limit**.
- Cuối cùng, câu lệnh thứ tư sẽ xóa nội dung của quan hệ **student_limit**.

Bây giờ chúng ta hãy thực thi **sample_script.pig** như hiển thị bên dưới.

```
$ pig -x mapreduce pig_data/sample_script.pig
```

--- Hết ---