

Phân tích dữ liệu Thương mại điện tử Shopee & Lazada

Ứng dụng Hệ sinh thái Hadoop: MapReduce – Hive – Spark

Nhóm sinh viên thực hiện:

Trần Quỳnh Xuân Như (24810092) | Trương Trung Nam (24810089) | Nguyễn Thị Ngọc Thơ (24810101)

Giảng viên hướng dẫn:

ThS. Trần Quang Khải


Lý do chọn đề tài

Sự bùng nổ dữ liệu

Thương mại điện tử tại Đông Nam Á bùng nổ mạnh mẽ, tạo ra hàng triệu giao dịch mỗi ngày. Các công cụ truyền thống (Excel, MySQL) bị quá tải.

Ứng dụng thực tiễn

Ứng dụng hệ sinh thái Hadoop là giải pháp tất yếu để lưu trữ, tính toán song song, khai phá insight hữu ích từ lượng dữ liệu cực lớn của Shopee và Lazada.



Mục tiêu nghiên cứu

- ✓ **Khai phá dữ liệu lớn:** Phân tích thành công hơn 283.000 bản ghi dữ liệu thực tế thu được từ Shopee và Lazada.
- ✓ **Làm chủ công nghệ Core:** Cài đặt, cấu hình và vận hành mượt mà hệ sinh thái Hadoop phân tán (HDFS, YARN).
- ✓ **Xây dựng Data Pipeline:** Hoàn thiện luồng xử lý trọn vẹn từ khâu thu thập, tiền xử lý, nạp HDFS đến trực quan hóa.
- ✓ **Đánh giá hiệu năng thực tế:** Đối chiếu sâu sắc tốc độ, tính năng giữa 3 engine hàng đầu: MapReduce, HiveQL, và PySpark.

Phân công nhiệm vụ

Họ và Tên	MSSV	Vai trò & Nhiệm vụ chính
Trần Quỳnh Xuân Như	24810092	Thu thập dữ liệu, làm sạch bằng Pandas; Khởi dựng slide và báo cáo chi tiết.
Trương Trung Nam	24810089	Cấu hình và cài đặt môi trường Hadoop, Apache Hive, Apache Spark trên Ubuntu; nạp dữ liệu HDFS.
Nguyễn Thị Ngọc Thơ	24810101	Phát triển thuật toán MapReduce (Python), truy vấn HiveQL, PySpark DataFrame; Thiết kế Dashboard.

Hệ sinh thái Hadoop & Công cụ



HDFS

Hệ thống lưu trữ tệp tin phân tán, chia nhỏ dữ liệu và lưu dự phòng trên toàn cụm server.



MapReduce

Mô hình lập trình phân tán thực thi song song hai tiến trình chính: Map và Reduce.



Apache Hive

Công cụ kho dữ liệu phân tán, cho phép quản lý và truy vấn cấu trúc thông qua cú pháp HiveQL tương tự SQL.



Apache Spark

Engine tính toán phân tán In-Memory (trên RAM), tăng tốc độ xử lý dữ liệu nhanh vượt bậc.

Cấu hình môi trường thực tế

Thành phần	Thông số kỹ thuật	Vai trò / Chức năng
Hệ điều hành	Ubuntu 22.04 LTS (chạy trên máy ảo VMware)	Môi trường chuẩn hóa tối ưu cho Big Data Hadoop
Bộ vi xử lý (CPU)	Intel Core i5 (Phân bổ 4 vCPUs cho máy ảo)	Thực thi xử lý tính toán song song, điều phối tác vụ
Bộ nhớ RAM	RAM 16 GB (Phân bổ 8 GB cho Ubuntu)	Đảm bảo tài nguyên vận hành mượt mà cho YARN và Spark
Hệ thống Hadoop	Hadoop Pseudo-distributed mode (1 Node)	Mô phỏng chính xác cấu trúc cụm Master-Worker thực tế

Tiền xử lý dữ liệu



1. Nạp dữ liệu

Đọc và kết hợp các tập dữ liệu gốc từ định dạng CSV thô của Lazada và Shopee bằng Pandas.



2. Làm sạch


Loại bỏ các bản ghi trùng lặp, xử lý giá trị thiếu (Null) ở trường thương hiệu và nội dung đánh giá.




3. Đồng bộ HDFS

Chuyển tệp dữ liệu đã được làm sạch (~185.000 dòng) lên phân vùng phân tán HDFS để sẵn sàng phân tích.

Số lượng & Giá theo ngành




Số lượng sản phẩm: External HDD dẫn đầu (40.42%), tiếp đến là Flash Drives (30.33%).




Giá trị trung bình: Ngành hàng Laptop có giá cao nhất, gấp 4 lần External HDD.

Sản phẩm & Thương hiệu



Smart TV và phụ kiện lưu trữ chiếm ưu thế lớn trong bảng xếp hạng top 10 bán chạy.




Mối tương quan: SanDisk có số sản phẩm cao nhất, Coocaa dẫn đầu về tổng review tích cực.

Phân bố đánh giá sao

So sánh Lazada vs Shopee

- **Lazada:** Phân bố đánh giá lệch mạnh về hướng cực kỳ tích cực. Lượt đánh giá 5 sao đạt tỷ lệ áp đảo **77.44%**.
- **Shopee:** Đánh giá trải đều và khách quan hơn. Điểm 5 sao đạt khoảng **32.89%**, cho thấy người dùng khá khe hơn.
- **Điểm chung:** Cả hai sàn đều giữ lượng đánh giá tiêu cực (1 sao) dao động ổn định trong khoảng 6% - 9.4%.



So sánh các công cụ

Tiêu chí đánh giá	MapReduce (Python)	Apache Hive (HiveQL)	Apache Spark (PySpark)
Cơ chế tính toán	Đọc/ghi đĩa liên tục	Dịch truy vấn thành MapReduce	Tính toán trực tiếp trên RAM
Tốc độ thực thi	Chậm nhất (I/O Disk)	Trung bình	Nhanh vượt trội (In-Memory)
Mức độ phức tạp	Dài, code logic phức tạp	Rất ngắn gọn, dễ dùng	Ngắn gọn, dễ bảo trì
Hỗ trợ mở rộng	Hạn chế tính năng mới	Data Warehouse tĩnh	Tích hợp Machine Learning, Stream

Dashboard trực quan

Trực quan hóa tập trung

- **Báo cáo sinh động:** Tích hợp 5 biểu đồ phân tích giúp nhà quản lý nắm bắt nhanh xu hướng của thị trường TMĐT.
- **Đối chiếu chính xác:** Kết quả thu được từ MapReduce, HiveQL, Spark hoàn toàn đồng nhất 100%.
- **Ứng dụng:** Giúp tối ưu hóa chính sách giá, cải thiện chất lượng dịch vụ dựa trên phân bố sao và lượng review thực tế.



Kết luận & Hạn chế

Kết quả đạt được

Xây dựng thành công luồng xử lý Data Pipeline hoàn chỉnh: Từ tiền xử lý bằng Pandas, nạp dữ liệu phân tán HDFS đến phân tích bằng MapReduce, HiveQL và Spark.

Đưa ra những insight thực tế, có tính áp dụng thực tiễn cao cho các doanh nghiệp TMĐT trong việc định hình chiến lược sản phẩm.

Hạn chế & Phát triển

Hệ thống chỉ chạy trên môi trường giả lập (Pseudo-distributed), chưa được triển khai trên hệ thống phân tán Multi-Node thực tế.

Hướng phát triển: Áp dụng phân tích cảm xúc (Sentiment Analysis) trên dữ liệu bình luận, tích hợp Kafka để phân tích luồng dữ liệu thời gian thực.

Hỏi & Đáp

Cảm ơn Thầy Cô và các bạn đã lắng nghe!


Trường Đại Học Sư Phạm Kỹ Thuật TP.HCM | Khoa Công Nghệ Thông Tin

Image Sources




https://media.istockphoto.com/id/1456867061/vector/line-icon-set-pattern-for-ecommerce-operations.jpg?s=612x612&w=0&k=20&c=AhjzlxvOSuz0aXt3C_AbGLs0RJwQDW2b5E8QL57RyqM=

Source: www.istockphoto.com




https://media.geeksforgeeks.org/wp-content/uploads/20240628002146/Figure_1.png

Source: www.geeksforgeeks.org




https://rkabacoff.github.io/datavis/datavis_files/figure-html/streamgraph1-1.png

Source: rkabacoff.github.io




<https://www.slideteam.net/wp/wp-content/uploads/2023/03/Competency-Rating-Of-Employees-Horizontal-Bar-Chart.png>

Source: www.slideteam.net



<https://inforiver.com/wp-content/uploads/image-165.png>

Source: inforiver.com



<https://journal.ahima.org/Portals/0/Figure%205.png>

Source: journal.ahima.org

Image Sources



<https://d1fa9n6k2ql7on.cloudfront.net/S0W69JPG30CRNPE1712330806.png>

Source: youexec.com